

Cases – Tractian

(Data Science)

Matheus Freire Wu
Outubro/2023

Case 1:

Análise no tempo e na frequência:

A primeira análise realizada sobre o sinal foi a criação da visualização do sinal puro no tempo em na frequência (FFT):

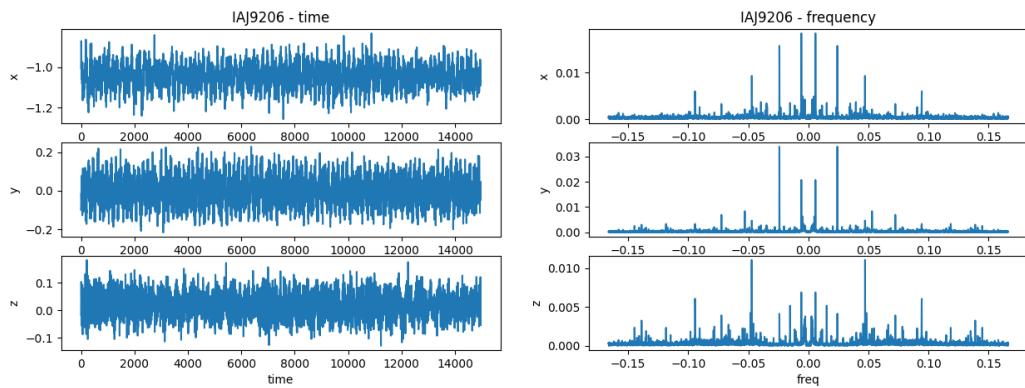


Figura 1. Sinal IAJ9206 tempo e frequência - bruto

Janelamento e filtro anti Aliasing

Para evitar potencial fenômeno de *Leakage*, foi aplicada uma janela de Hamming. E em seguida, aplicado um filtro *Butterworth* de 8^a ordem, projetado com *cutoff* na frequência de corte de Nyquist de cada sinal para evitar *Aliasing*.

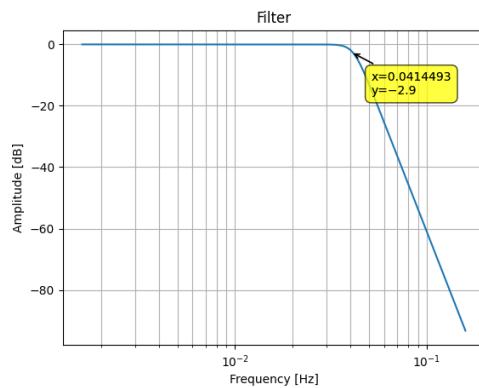


Figura 2. Filtro Butterworth (analógico) para sinal IAJ9206.

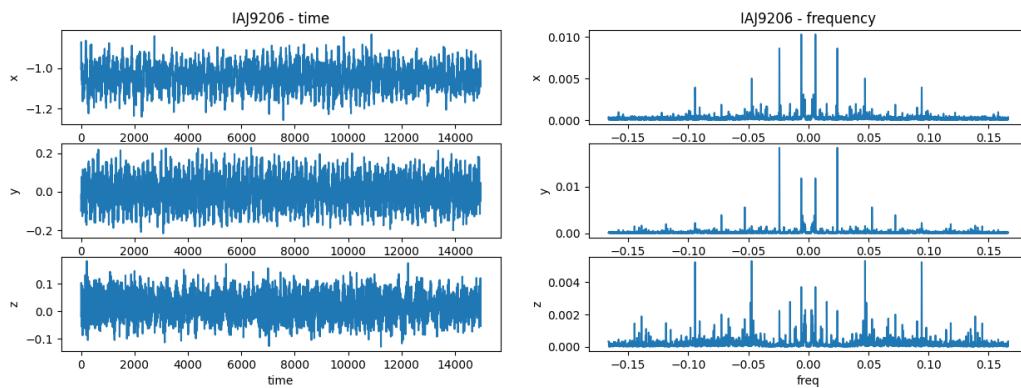


Figura 3. Sinal IAJ9206 tempo e frequência – Hamming.

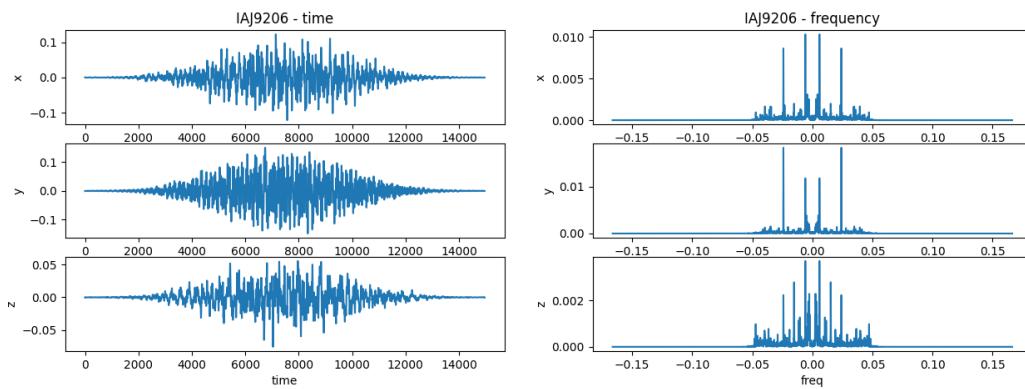


Figura 4. Sinal IAJ9206 tempo e frequência – Filtrado.

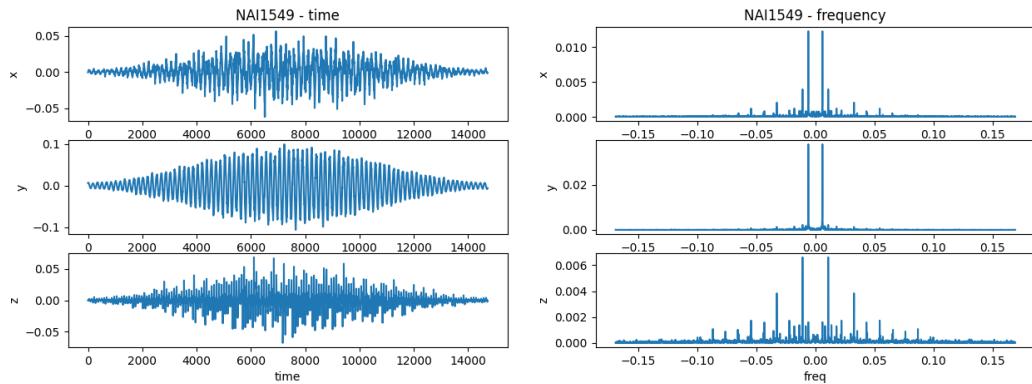


Figura 5. Sinal NAI1549 tempo e frequência – Hamming.

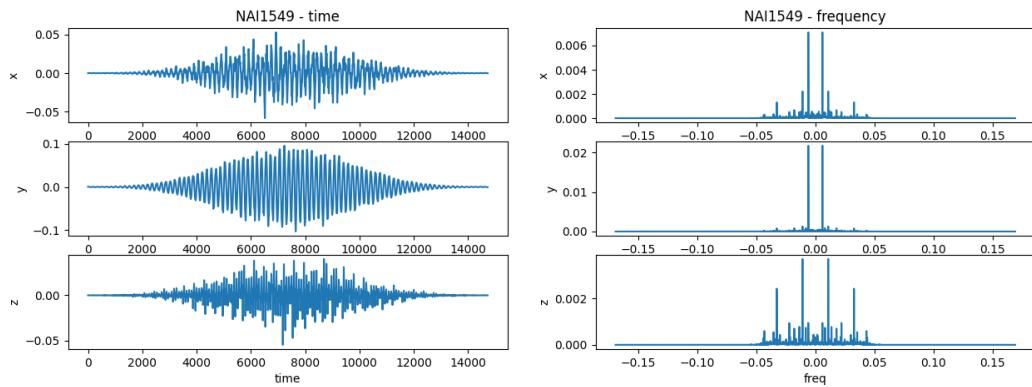


Figura 6. Sinal NAI1549 tempo e frequência – Filtrado.

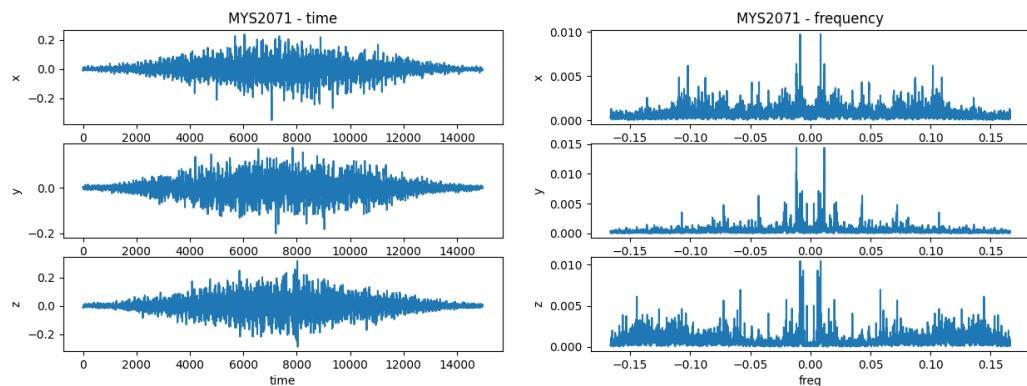


Figura 7. Sinal MYS2071 tempo e frequência – Hamming.

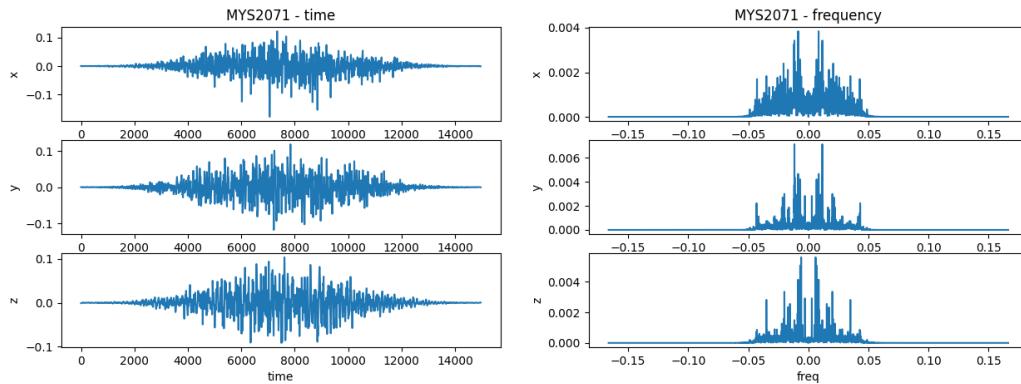


Figura 8. Sinal MYS2071 tempo e frequência – Filtro.

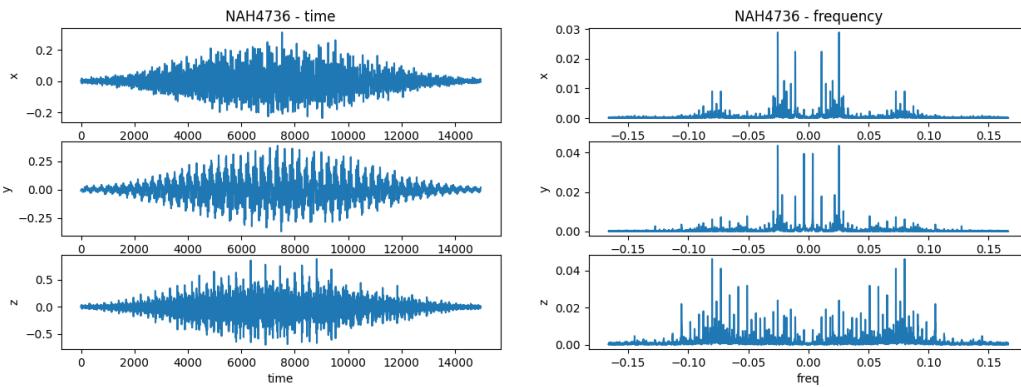


Figura 9. Sinal NAH4736 tempo e frequência – Hamming.

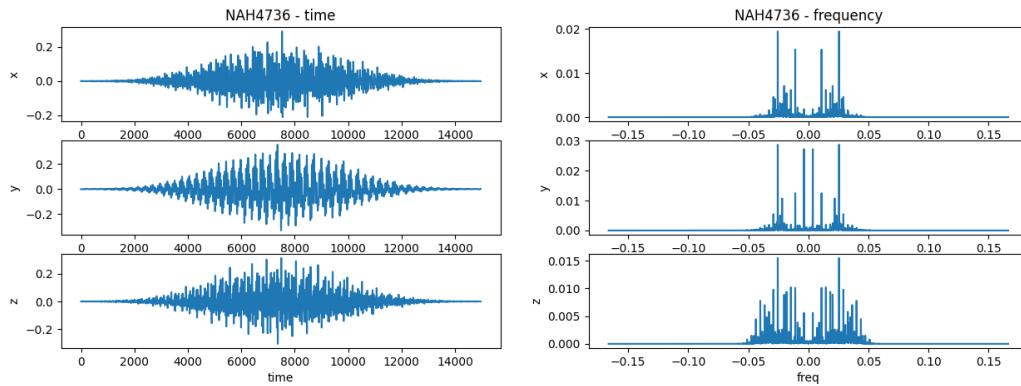


Figura 10. Sinal NAH4736 tempo e frequência – Filtro.

Detecção de Harmônicas

Para detecção de picos harmônicos foi proposto o seguinte algoritmo:

- Dentro as três direções, localizar a menor frequência com maior pico, dentre as três direções (frequência fundamental);

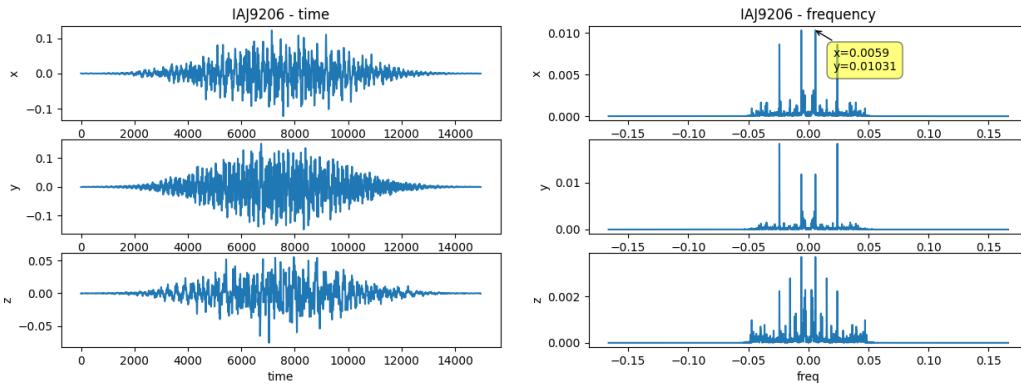


Figura 11. Determinação da frequência fundamental.

- A partir da frequência fundamental, varrer as proximidades (mais ou menos 10 passos) dos múltiplos da frequência fundamental buscando picos;
- Repetir a busca até a frequência de Nyquist do sinal.

x	y	z	freq	mult
0.010311	0.011772	0.003698	0.005880	1
0.000882	0.001122	0.001128	0.011759	2
0.000474	0.000268	0.000130	0.017639	3
0.008624	0.018304	0.002227	0.023519	4
0.000394	0.000641	0.000532	0.029398	5
0.001643	0.001513	0.000374	0.035278	6
0.000625	0.000896	0.000299	0.041158	7

Figura 12. Sinal IAJ9206 – Harmonicas.

x	y	z	freq	mult
0.007091	0.021730	0.000943	0.005977	1
0.000590	0.000215	0.000273	0.011954	2
0.000670	0.000850	0.000699	0.017931	3
0.000108	0.000050	0.000114	0.023908	4
0.000206	0.000171	0.000431	0.029885	5
0.000332	0.000155	0.000548	0.035862	6
0.000074	0.000055	0.000134	0.041840	7

Figura 13. Sinal NAI1549 – Harmonicas.

x	y	z	freq	mult
0.001814	0.001321	0.005594	0.006013	1
0.003425	0.007131	0.001490	0.012027	2
0.000992	0.000509	0.001148	0.018040	3
0.001827	0.000677	0.000421	0.024053	4
0.001352	0.000407	0.000424	0.030066	5
0.000748	0.000474	0.000378	0.036080	6

Figura 14. Sinal MYS2071 – Harmonicas.

x	y	z	freq	mult
0.019419	0.028708	0.015489	0.025523	1

Figura 15. Sinal NAH4736 – Harmonicas.

Para o sinal NAH4 foram notadas potenciais sub-harmônicas. Porém, como os maiores picos se deram no meio do domínio da frequência (aproximadamente 0,025Hz), não foram encontradas outras harmônicas pelo algoritmo proposto.

Case 2:

Visualização dos elementos

Para cada elemento são inseridos diagramas representando o histórico de atuação de cada elementos (eixo x em segundos). Para os diagramas de aceleração a linha vermelha representa 5% acima do valor mínimo do sinal para determinar situação de *downtime*.

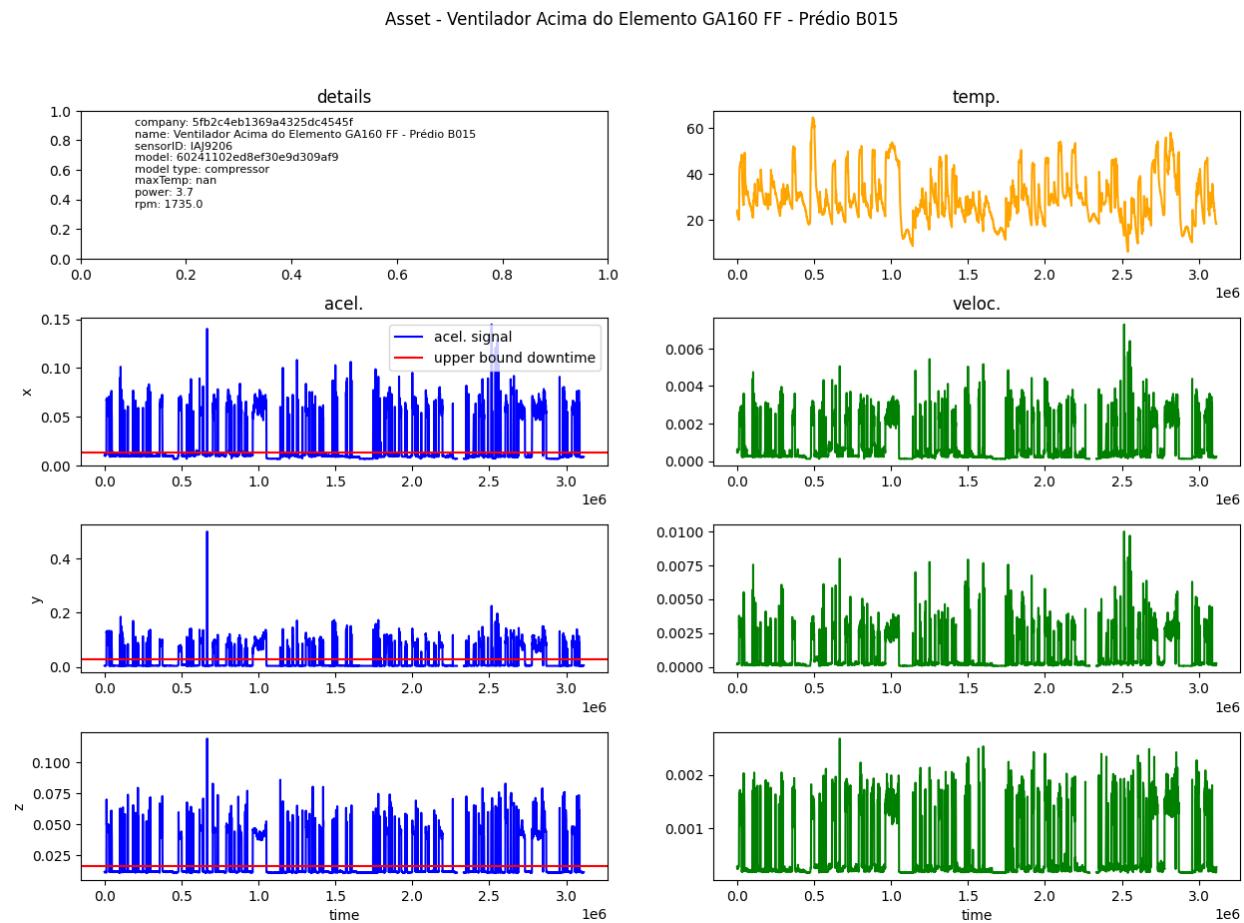


Figura 16. Dados - Asset00

Asset - RDF-61.1

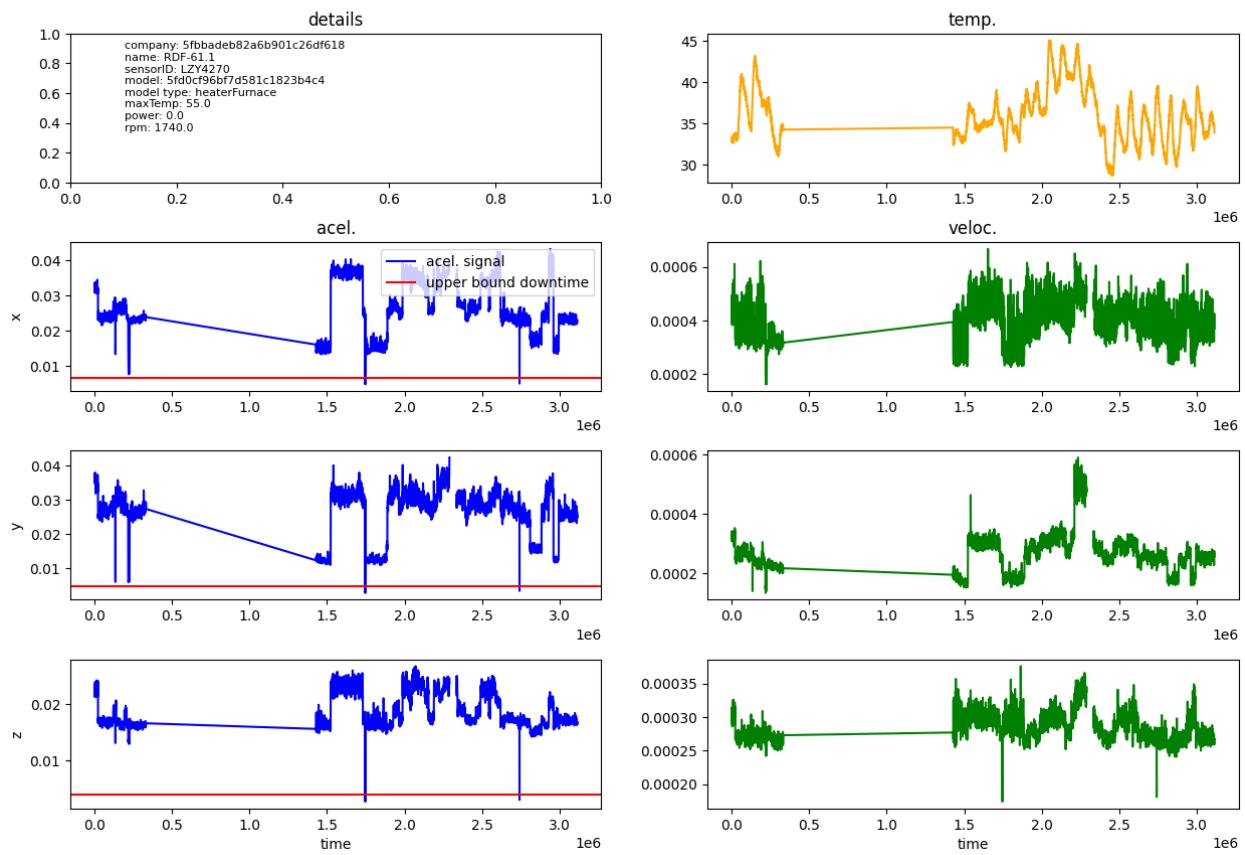


Figura 17. Dados - Asset01

Asset - TRANSFORMADOR 500 KVA N°1

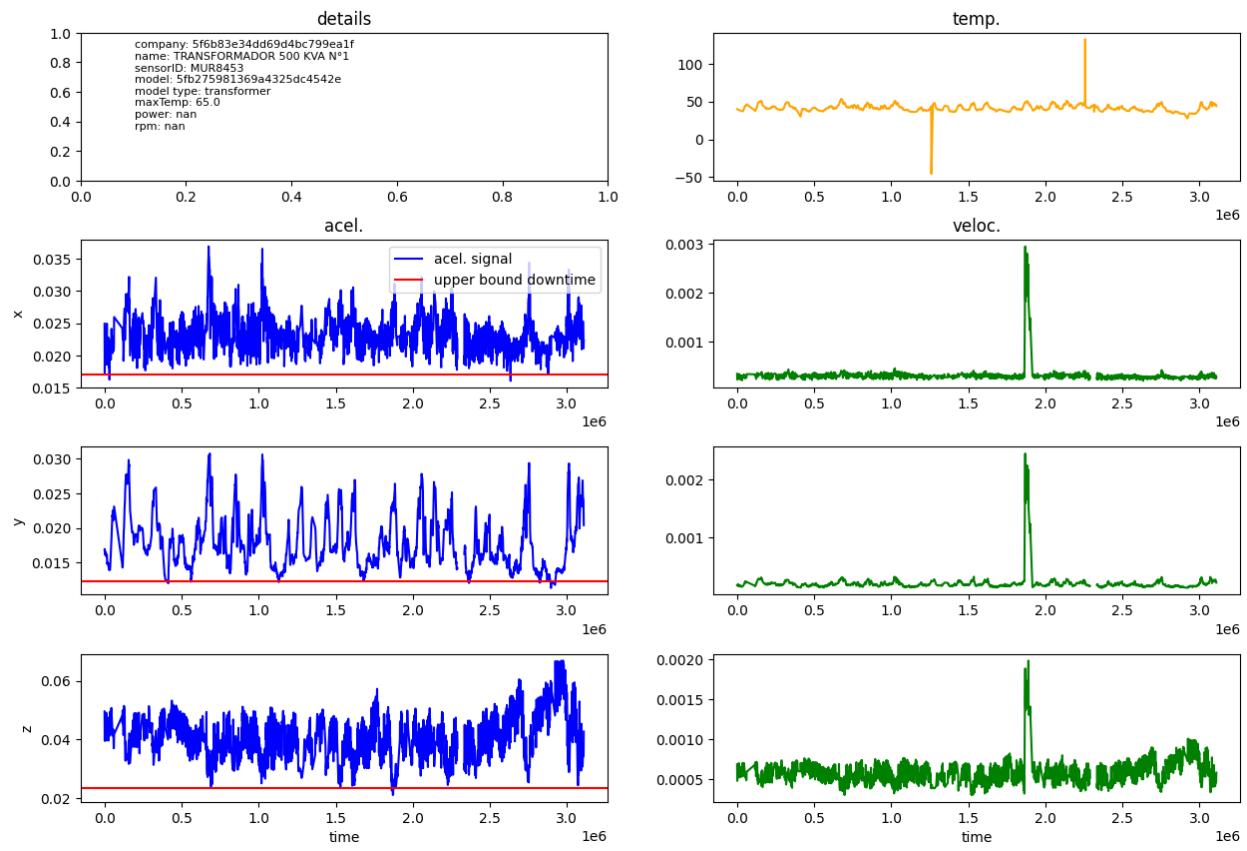


Figura 18. Dados - Asset02

Asset - Motor Bomba - Tanque de Expansão Tubo Verde

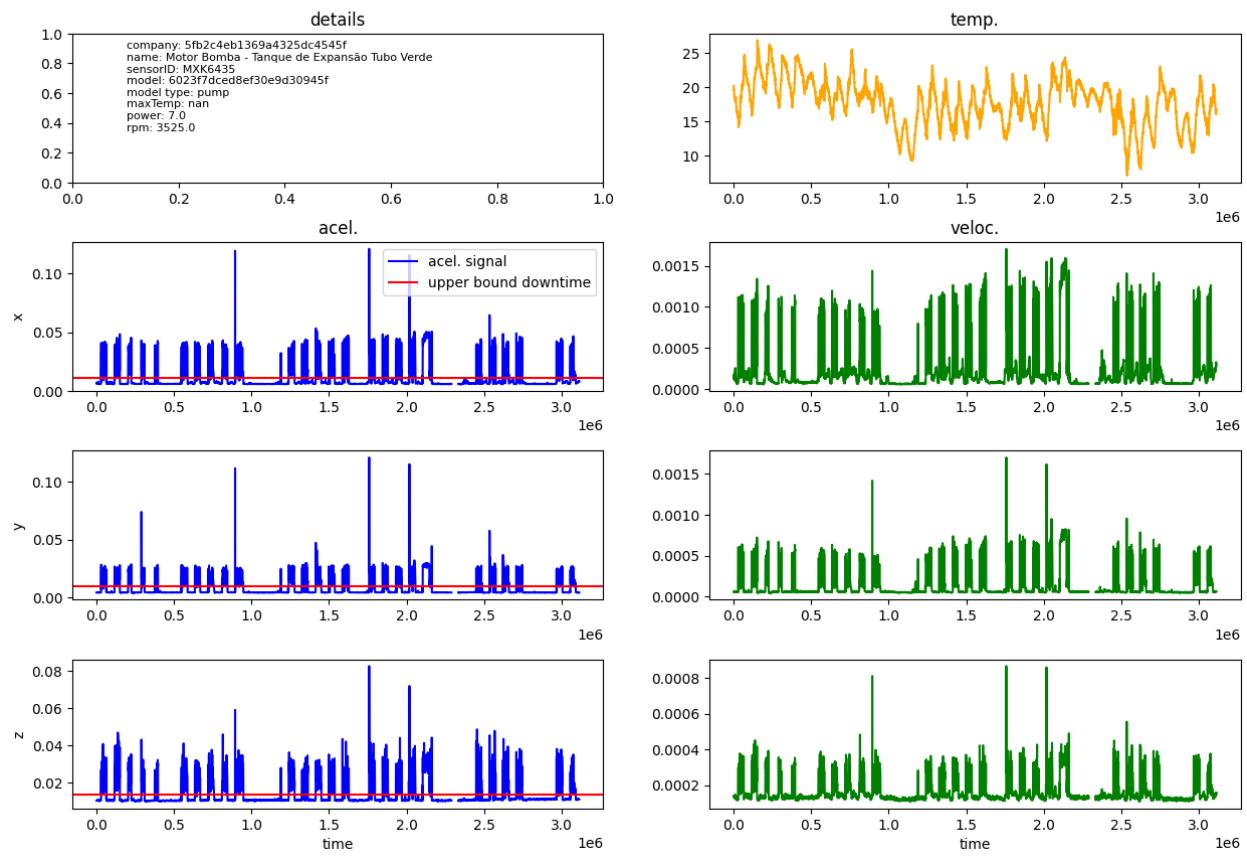


Figura 19. Dados - Asset03

Asset - CAG1- BAGS.12- Motor

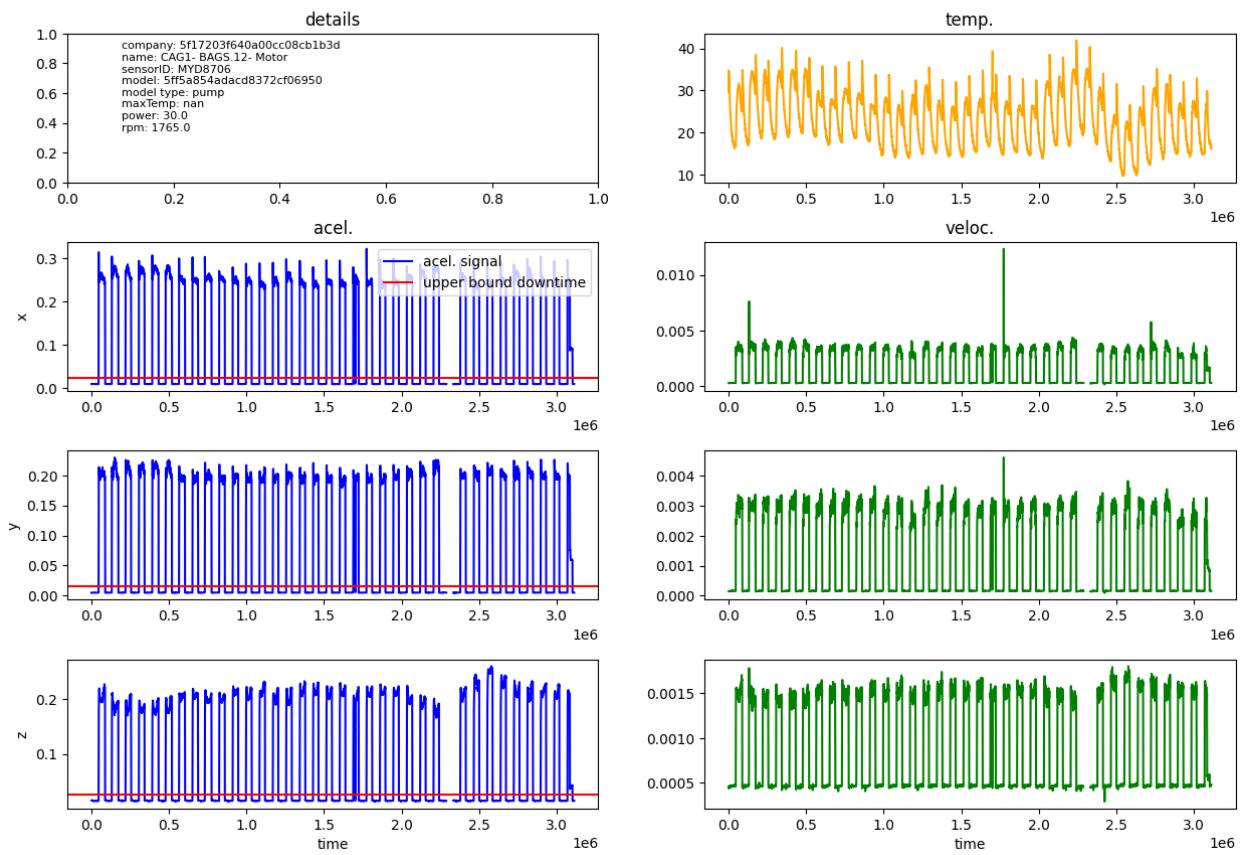


Figura 20. Dados - Asset04

Asset - VTF-61.1

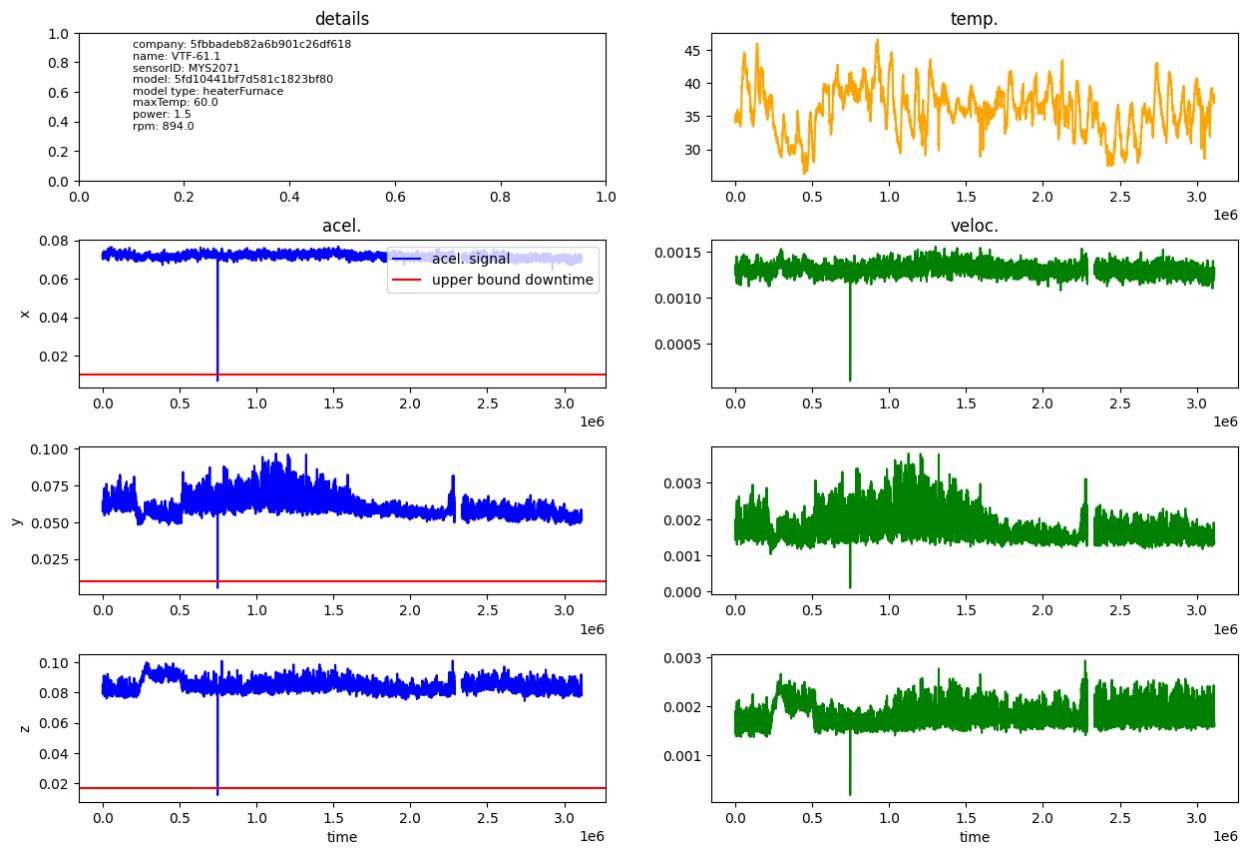


Figura 21. Dados - Asset05

Asset - Boko MA-1510 - Motor 2 da UH

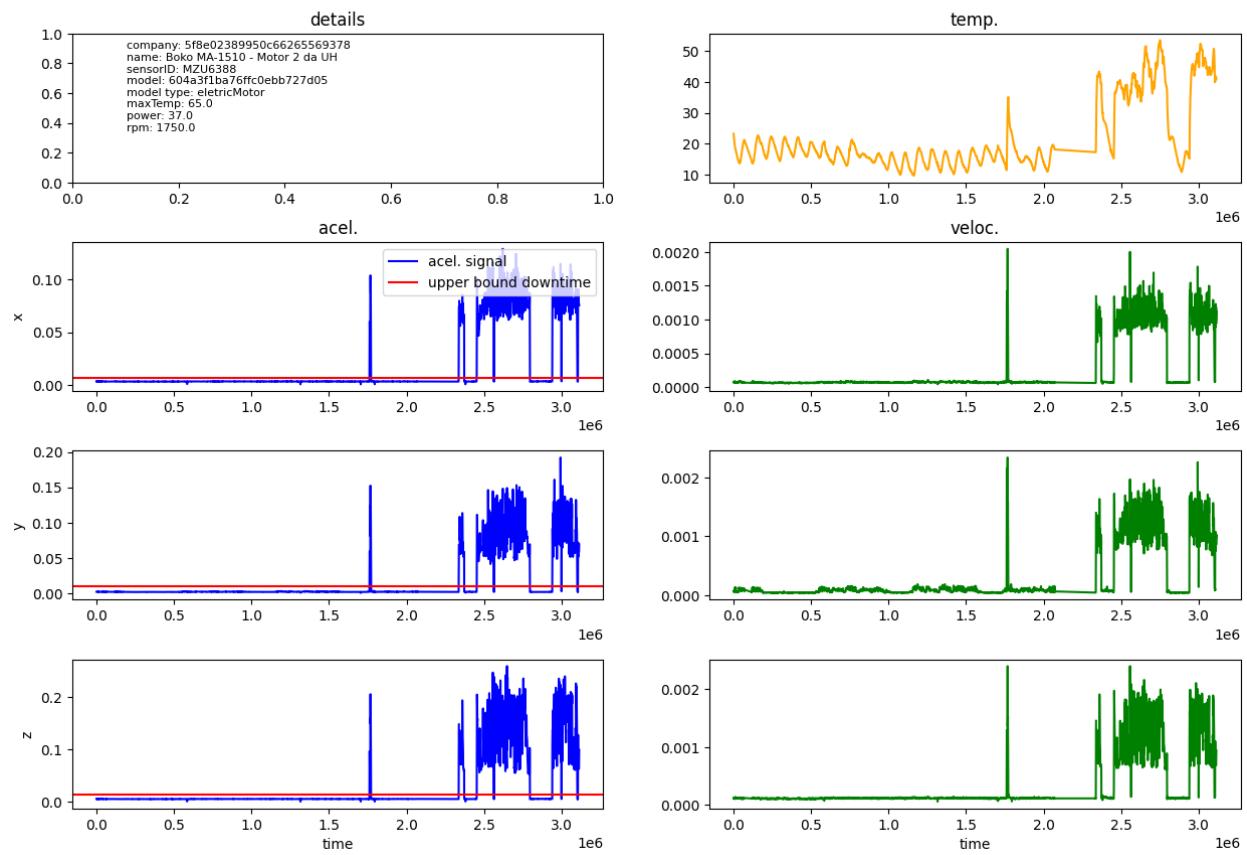


Figura 22. Dados - Asset06

Asset - Ventilador -GA75 FF - Prédio B104

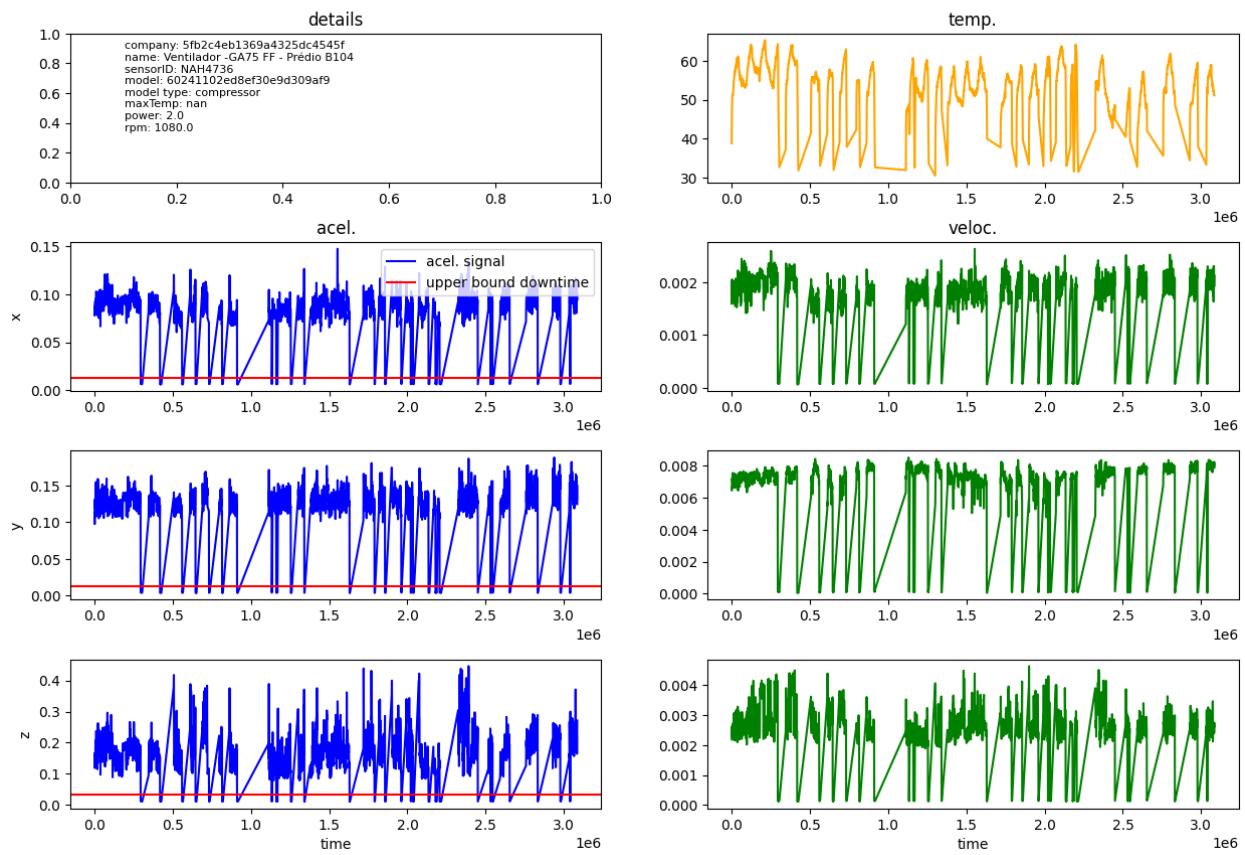


Figura 23. Dados - Asset07

Asset - CAG1- BAGS.3- Motor

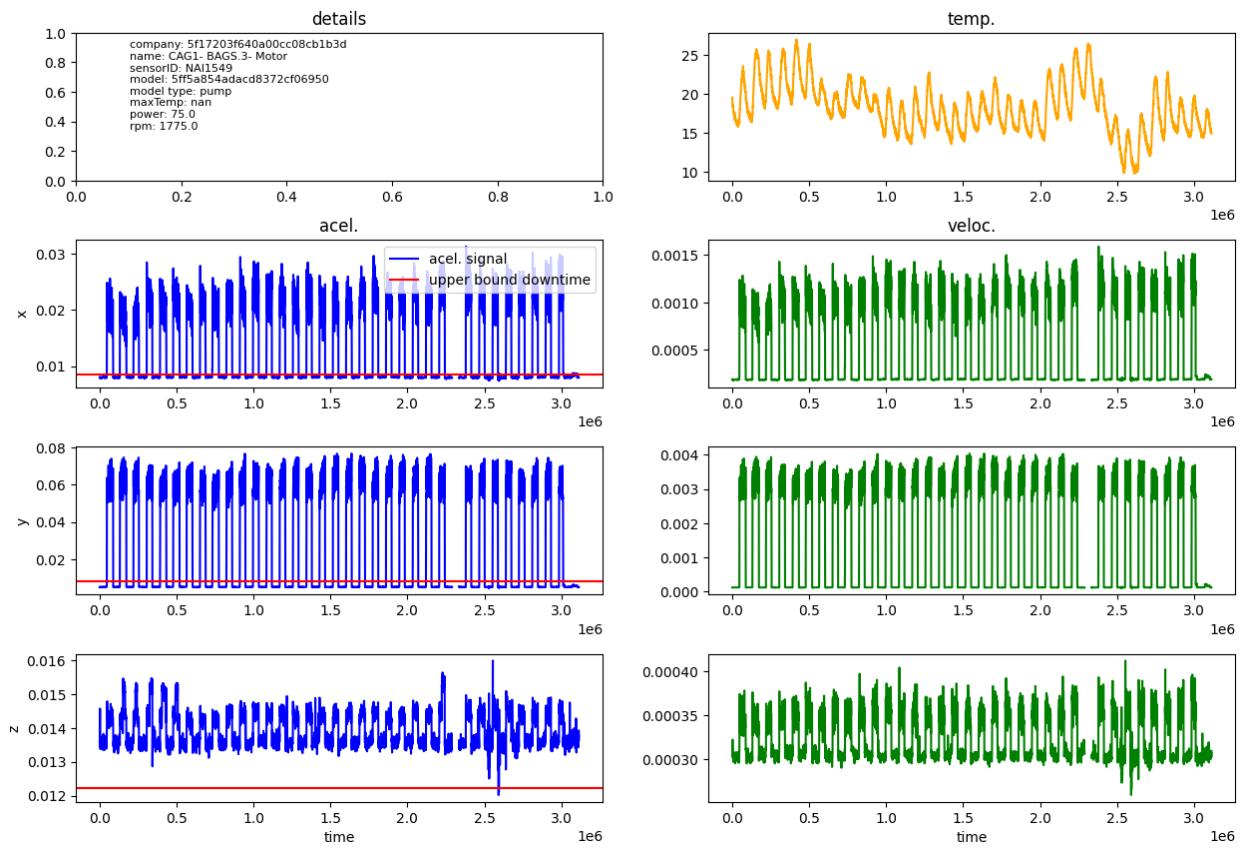


Figura 24. Dados - Asset08

Asset - ROTULADORA SIDEL

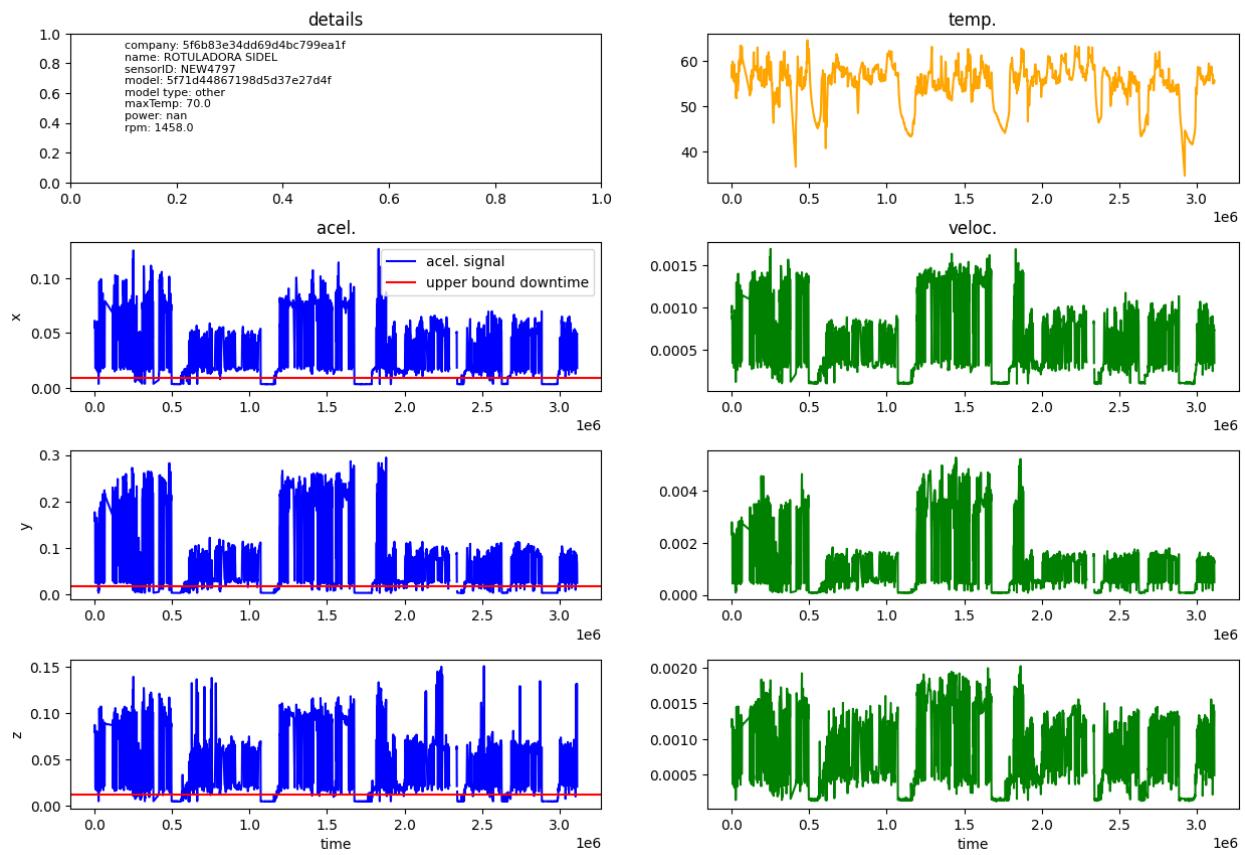


Figura 25. Dados - Asset09

Cálculo de *downtime* e *uptime*

O tempo de *Downtime* foi definido como a soma dos casos em que ocorrem pelo menos uma das três condições a seguir:

1. Medições nulas;
2. Gaps de tempo de medição maiores que 10% da média de amostragem;
3. Patamares de vibração abaixo de 5% do valor mínimo (linhas vermelhas nos diagramas de aceleração da seção anterior).

Ambas as condições dos itens 2 e 3 foram ajustados visualmente, supondo que há uma flutuação no delay de início de medição e no *bias/ganho* nos sensores.

```
Ventilador Acima do Elemento GA160 FF - Prédio B015 - uptime: 642593 s, downtime: 2471612 s - 79.37%
RDF-61.1 - uptime: 1908978 s, downtime: 1205098 s - 38.70%
TRANSFORMADOR 500 KVA N°1 - uptime: 1687716 s, downtime: 1421396 s - 45.72%
Motor Bomba - Tanque de Expansão Tubo Verde - uptime: 692344 s, downtime: 2421593 s - 77.77%
CAG1- BAGS.12- Motor - uptime: 1266423 s, downtime: 1847763 s - 59.33%
VTF-61.1 - uptime: 3022002 s, downtime: 92104 s - 2.96%
Boko MA-1510 - Motor 2 da UH - uptime: 372505 s, downtime: 2741936 s - 88.04%
Ventilador -GA75 FF - Prédio B104 - uptime: 1649779 s, downtime: 1434967 s - 46.52%
CAG1- BAGS.3- Motor - uptime: 1224573 s, downtime: 1889622 s - 60.68%
ROTULADORA SIDEL - uptime: 1422934 s, downtime: 1691270 s - 54.31%
```

Figura 26. Downtime estimado para cada elemento

Identificação de variação de padrão de vibração

Existem diferentes formas de calcular variações de padrões de sinais, sendo ideal realizar testes para verificar qual melhor se adequa a situação.

Neste caso, é proposto utilizar redes neurais convolucionais, treinadas para cada elemento, buscando capturar padrões de funcionamento das máquinas a partir de janelas móveis. A partir do erro quadrático entre o valor predito e o real, é determinado um patamar que estabeleça mudanças de padrão de vibração.

Parâmetros básicos:

- Tamanho de janela móvel: 5% do sinal
- Tamanho do passo: 4% do sinal (conjunto de treino)

Estrutura da rede neural:

- Convolução: 3 canais com saída de tamanho 50% da janela móvel
- ReLu
- Convolução: 10% da janela móvel
- Relu
- Camada completa
- Camada linear com vetor de saída de tamanho 3.

Otimizador:

- Adam
- Objetivo: minimizar erro quadrático
- 1000 iterações

Foi considerado como condição de mudança de padrão de vibração uma adaptação do critério outliers interquartil. Foi obtida a distância “interquartil” entre o 0 a 90% do erro (acima do patamar máximo de *downtime*), e estabelecido como faixa de corte:

$$med(erro) + 1,5 \times IQR[0, 90\%]$$

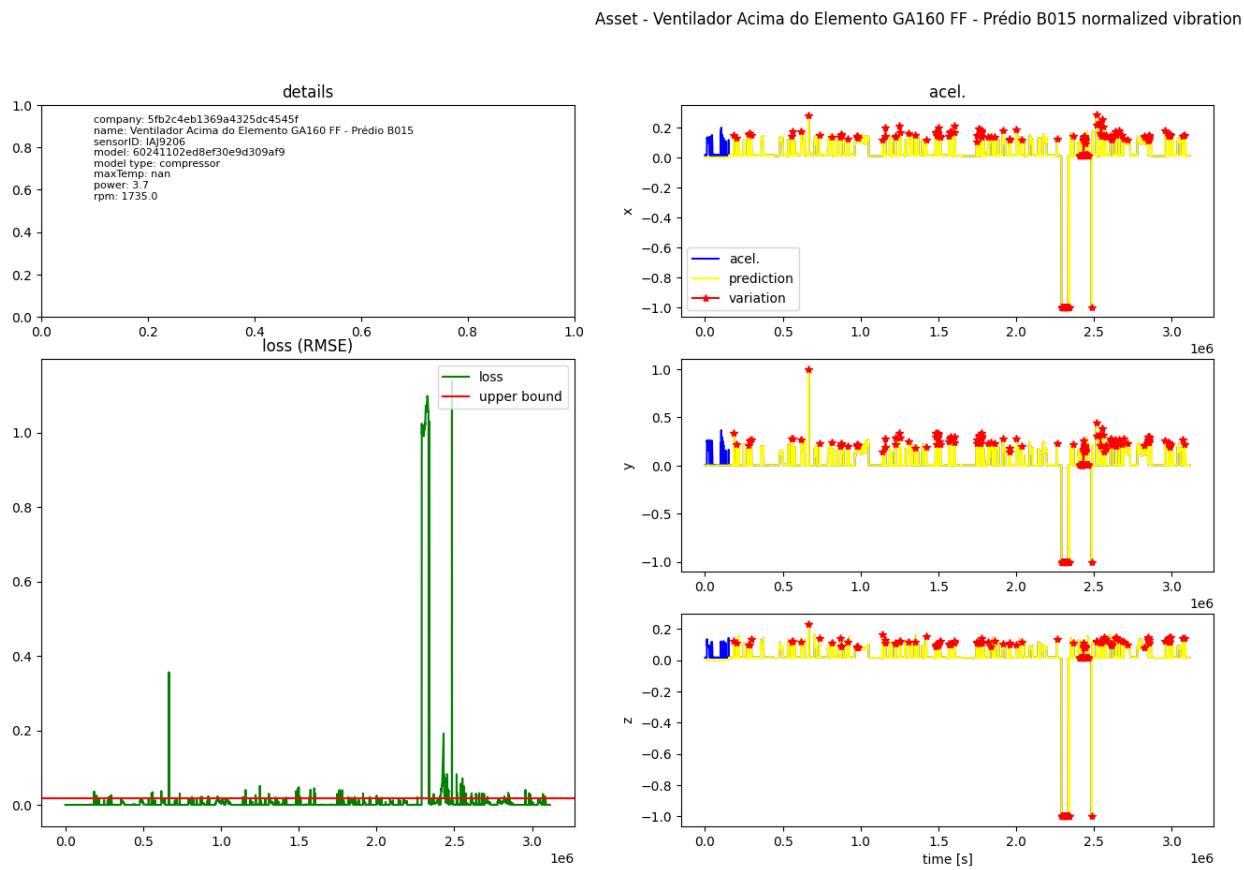


Figura 27. Detecção de variação - Asset00

Asset - RDF-61.1 normalized vibration

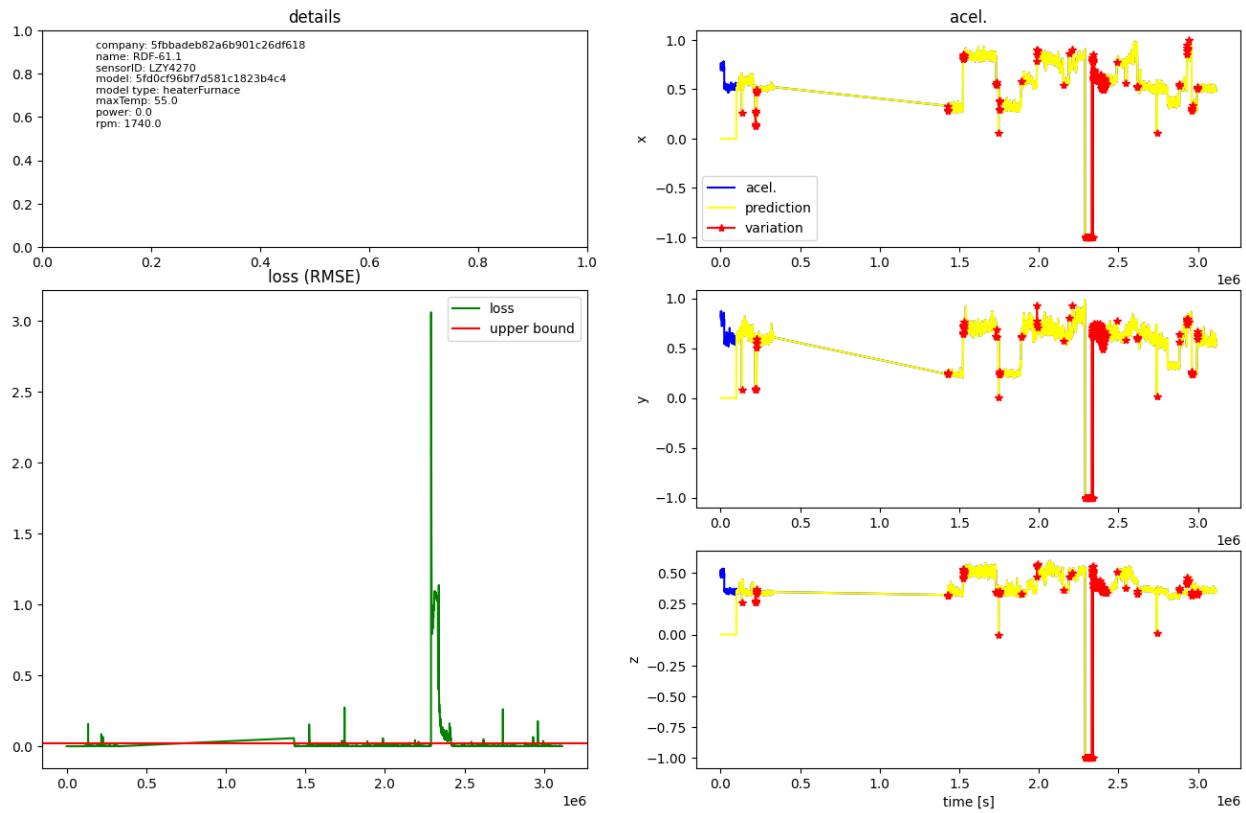


Figura 28. Detecção de variação - Asset01

Asset - TRANSFORMADOR 500 KVA N°1 normalized vibration

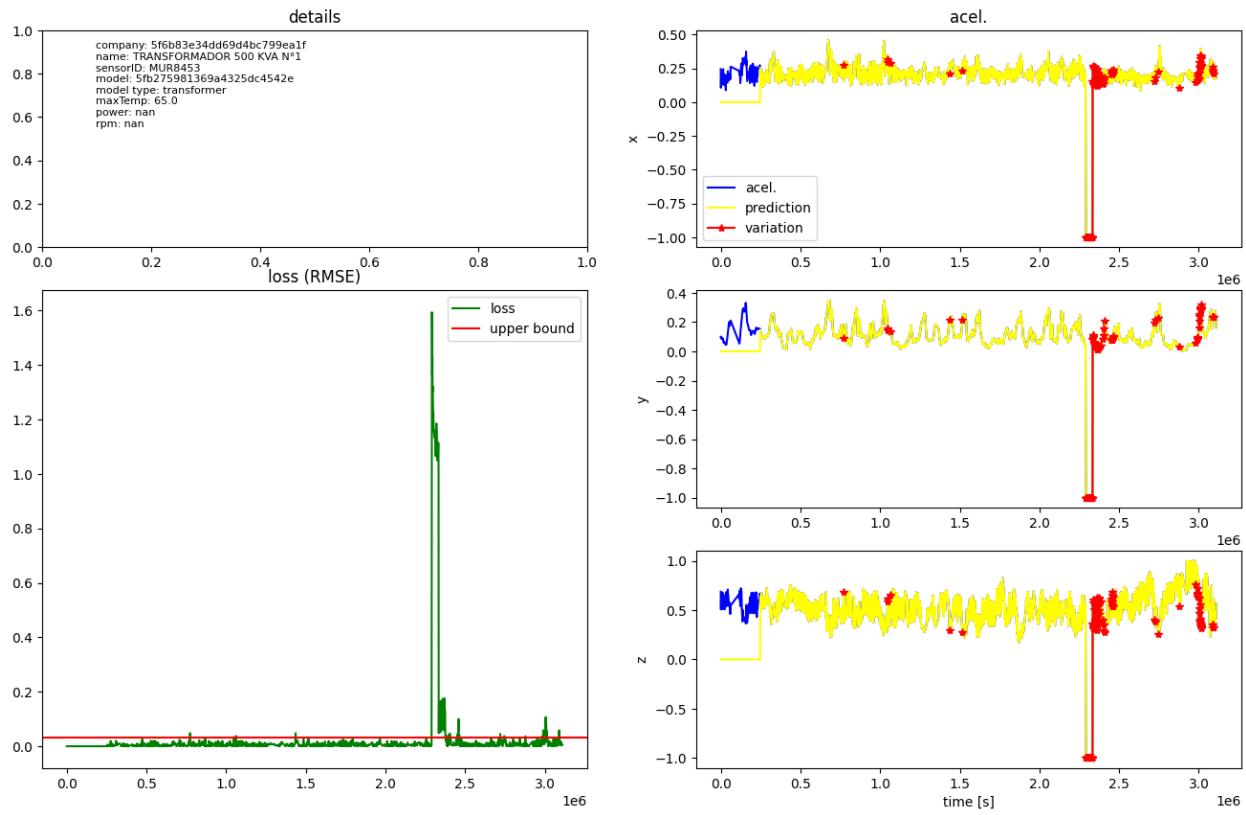


Figura 29. Detecção de variação - Asset02

Asset - Motor Bomba - Tanque de Expansão Tubo Verde normalized vibration

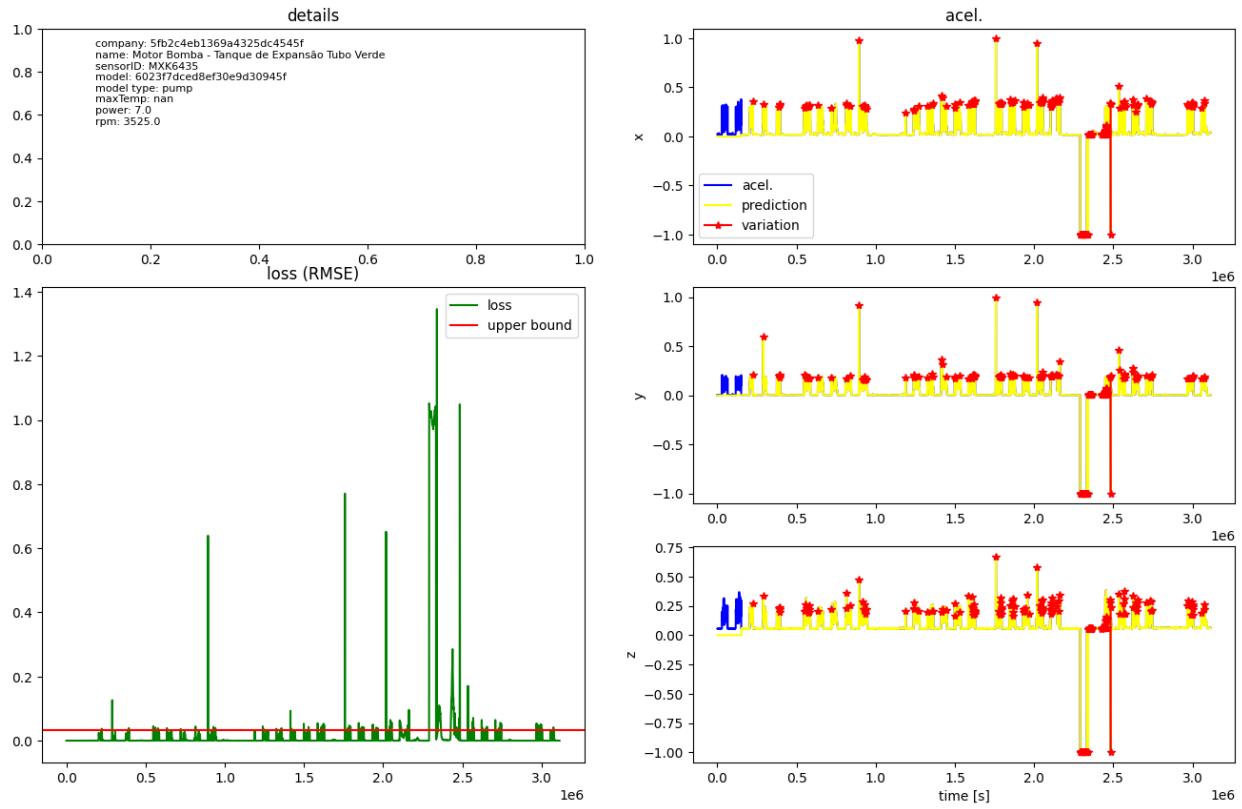


Figura 30. Detecção de variação - Asset03

Asset - CAG1- BAGS.12- Motor normalized vibration

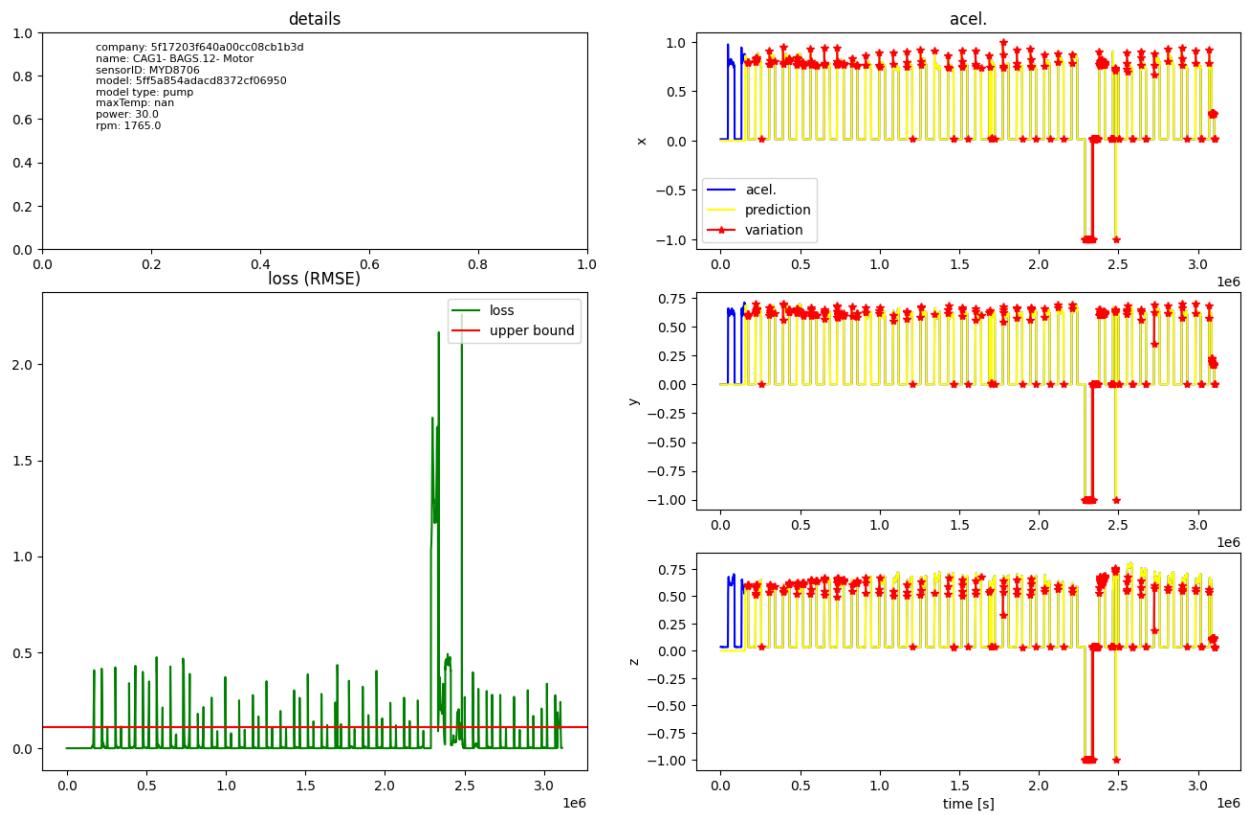


Figura 31. Detecção de variação - Asset04

Asset - VTF-61.1 normalized vibration

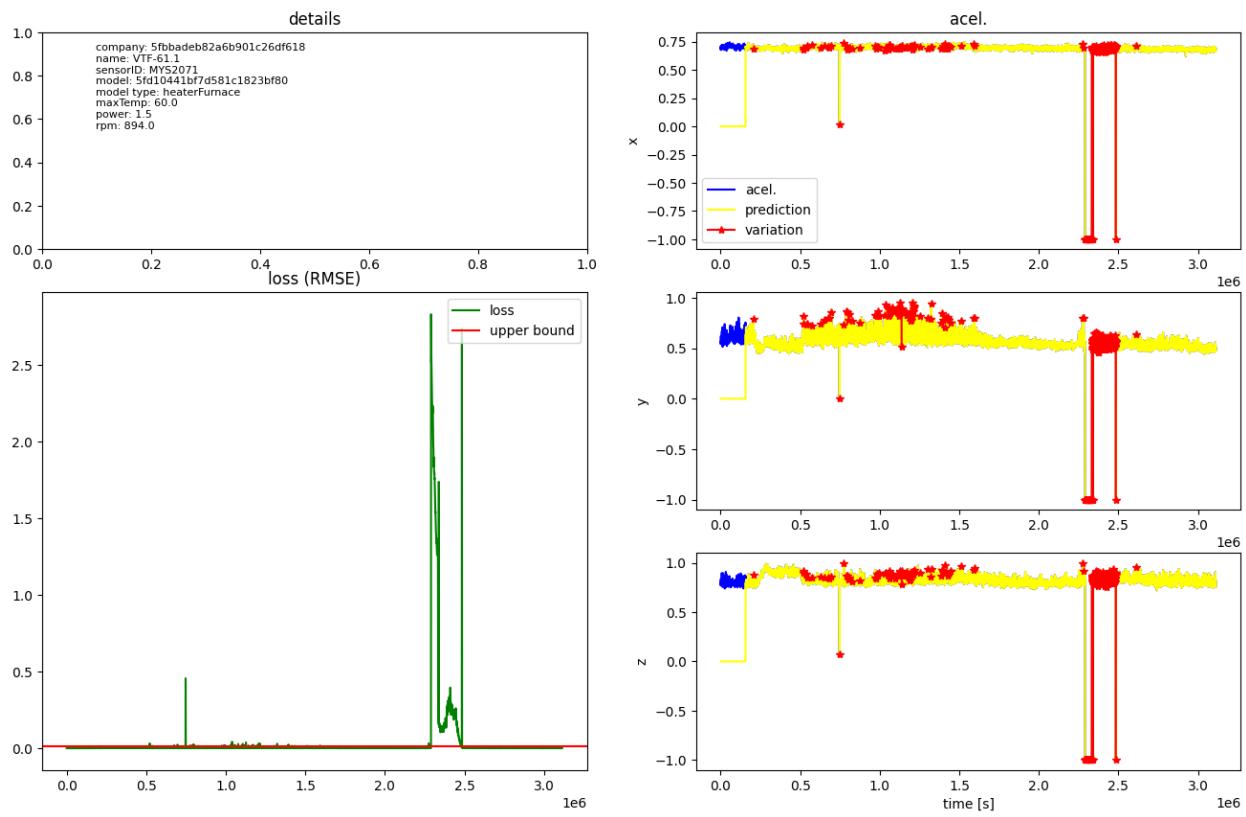


Figura 32. Detecção de variação - Asset05

Asset - Boko MA-1510 - Motor 2 da UH normalized vibration

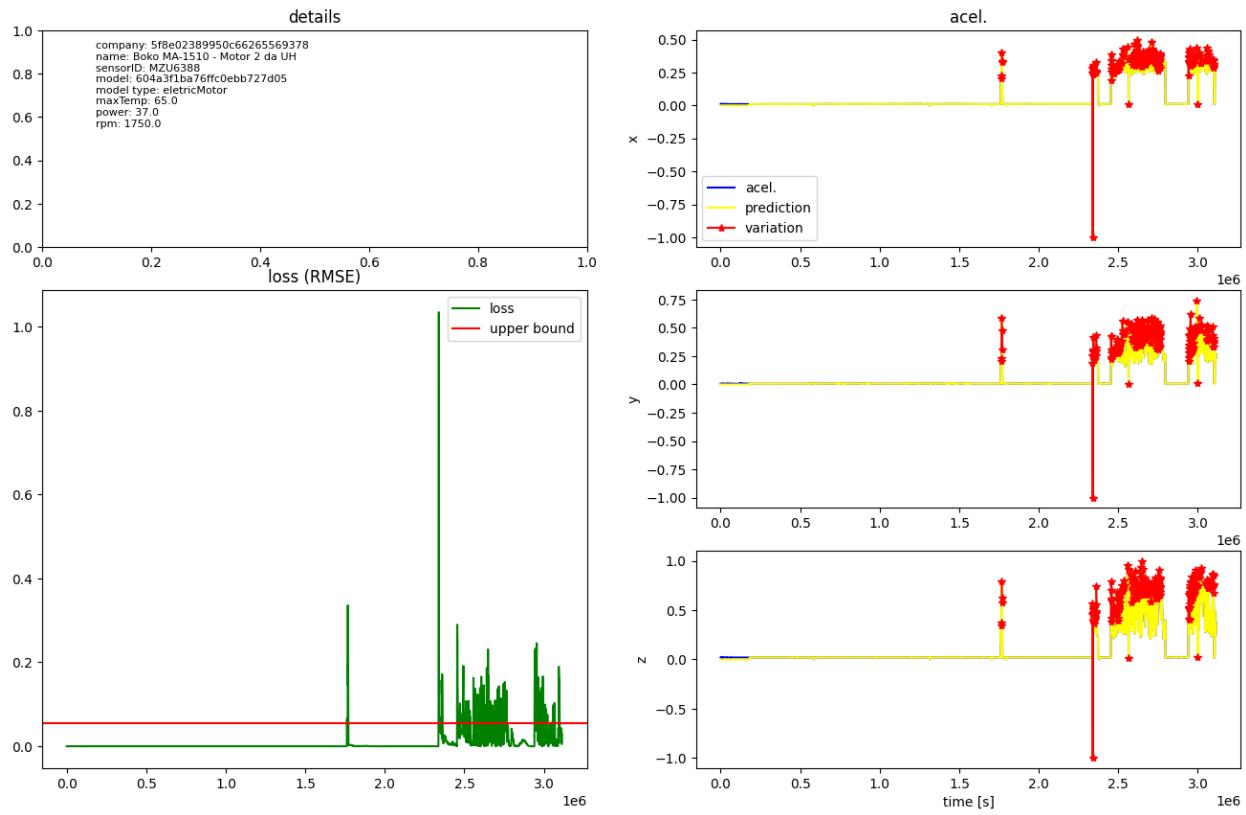


Figura 33. Detecção de variação - Asset06

Asset - Ventilador -GA75 FF - Prédio B104 normalized vibration

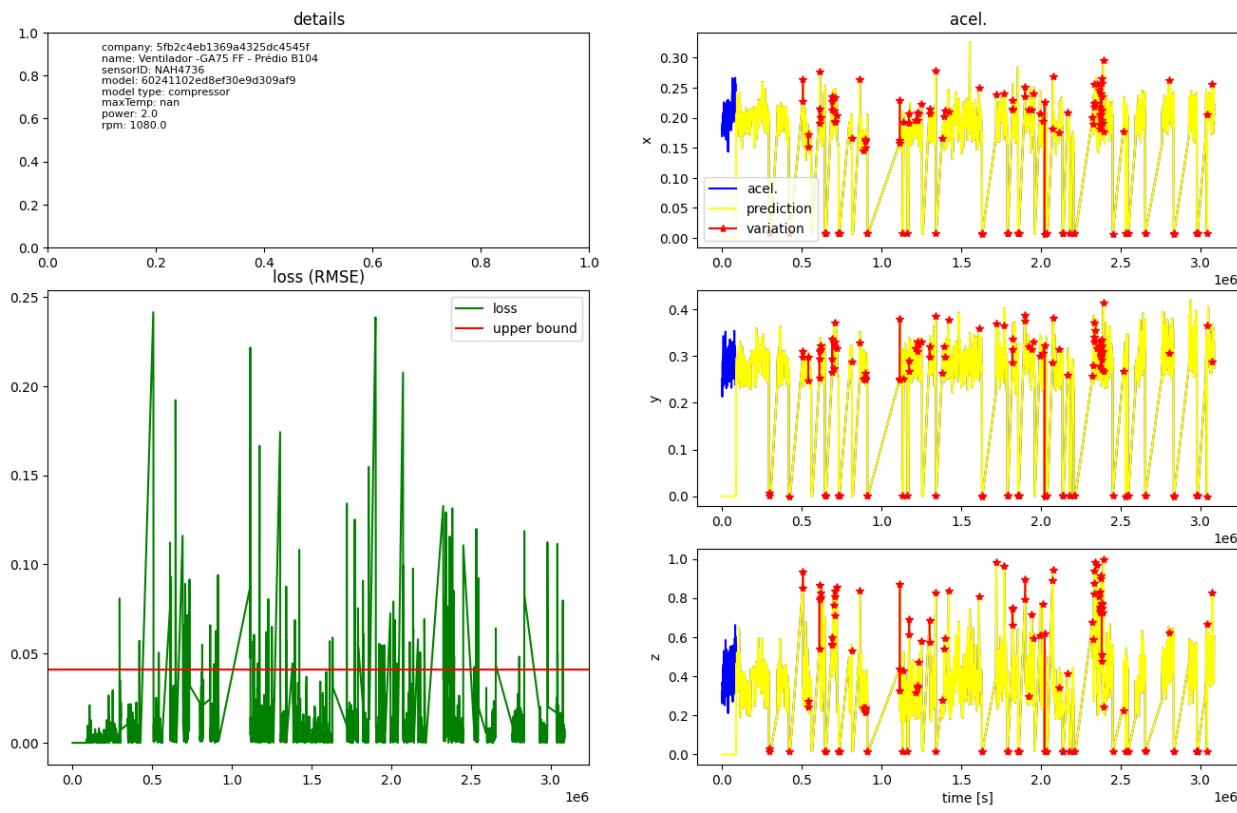


Figura 34. Detecção de variação - Asset07

Asset - CAG1- BAGS.3- Motor normalized vibration

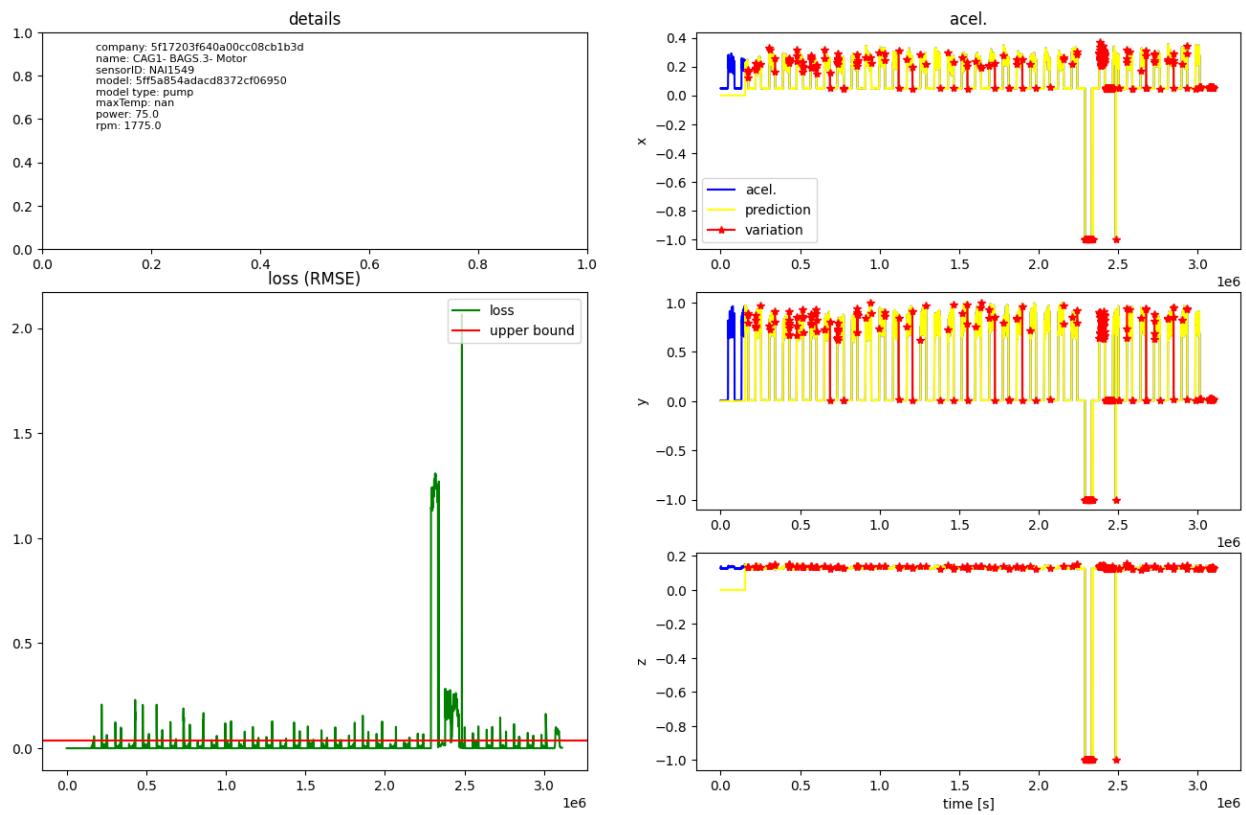


Figura 35. Detecção de variação - Asset08

Asset - ROTULADORA SIDEL normalized vibration

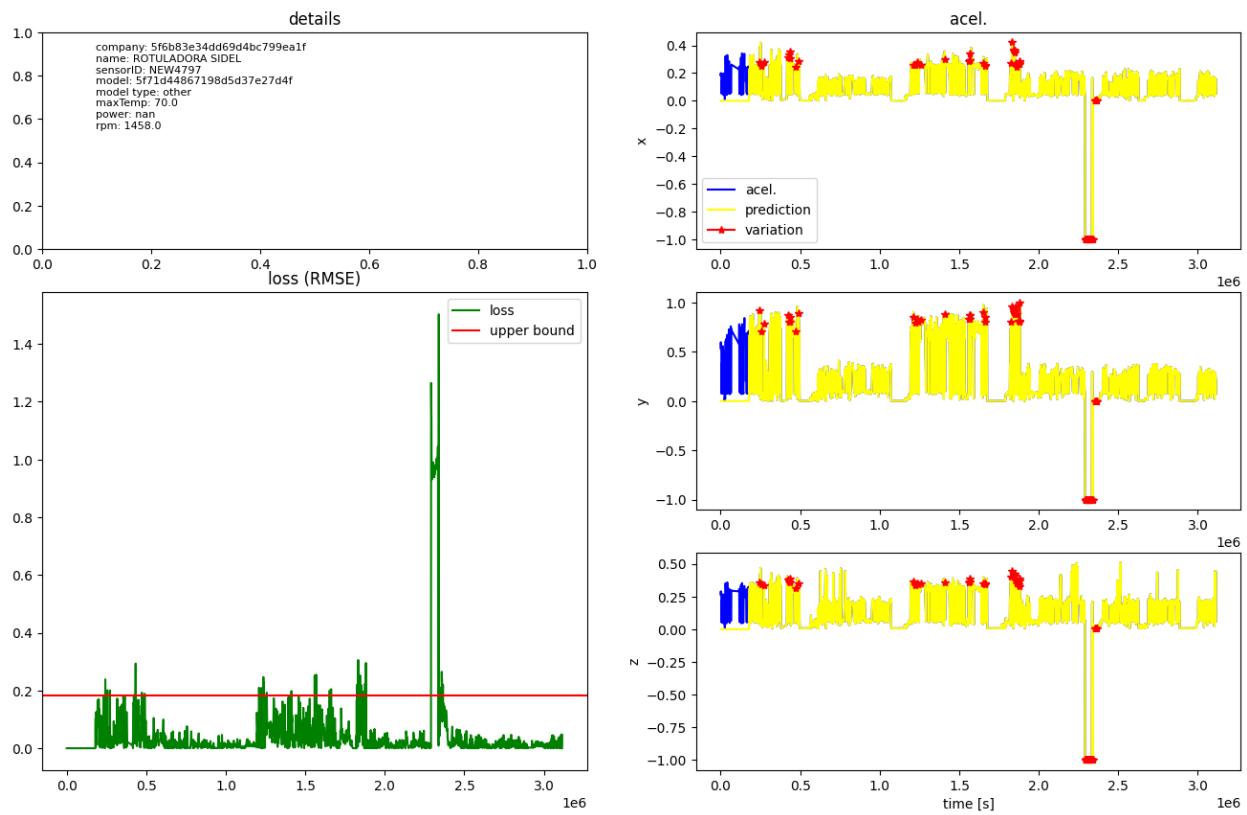


Figura 36. Detecção de variação - Asset09

Identificação de falhas

Para a detecção de potenciais falhas, é utilizado o método não-supervisionado de *Isolation Forest* aplicado sobre os pontos de variação de vibração detectados no item 3. Nesse caso, são considerados os vetores de erro de predição, sinal de temperatura e módulo velocidade normalizados. O método é capaz de identificar e separar casos de outliers entre múltiplas *features*.

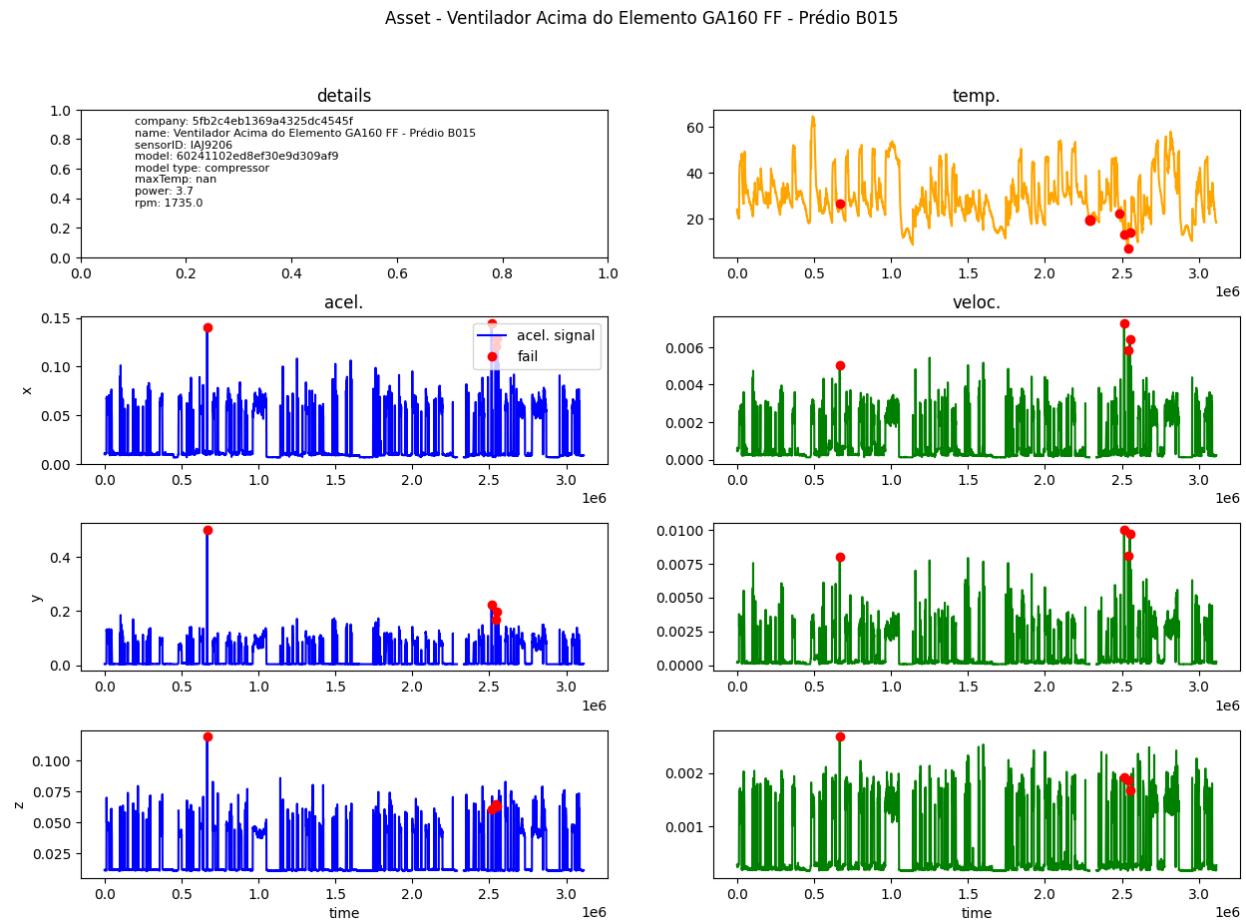


Figura 37. Detecção de falhas - Asset00

Asset - RDF-61.1

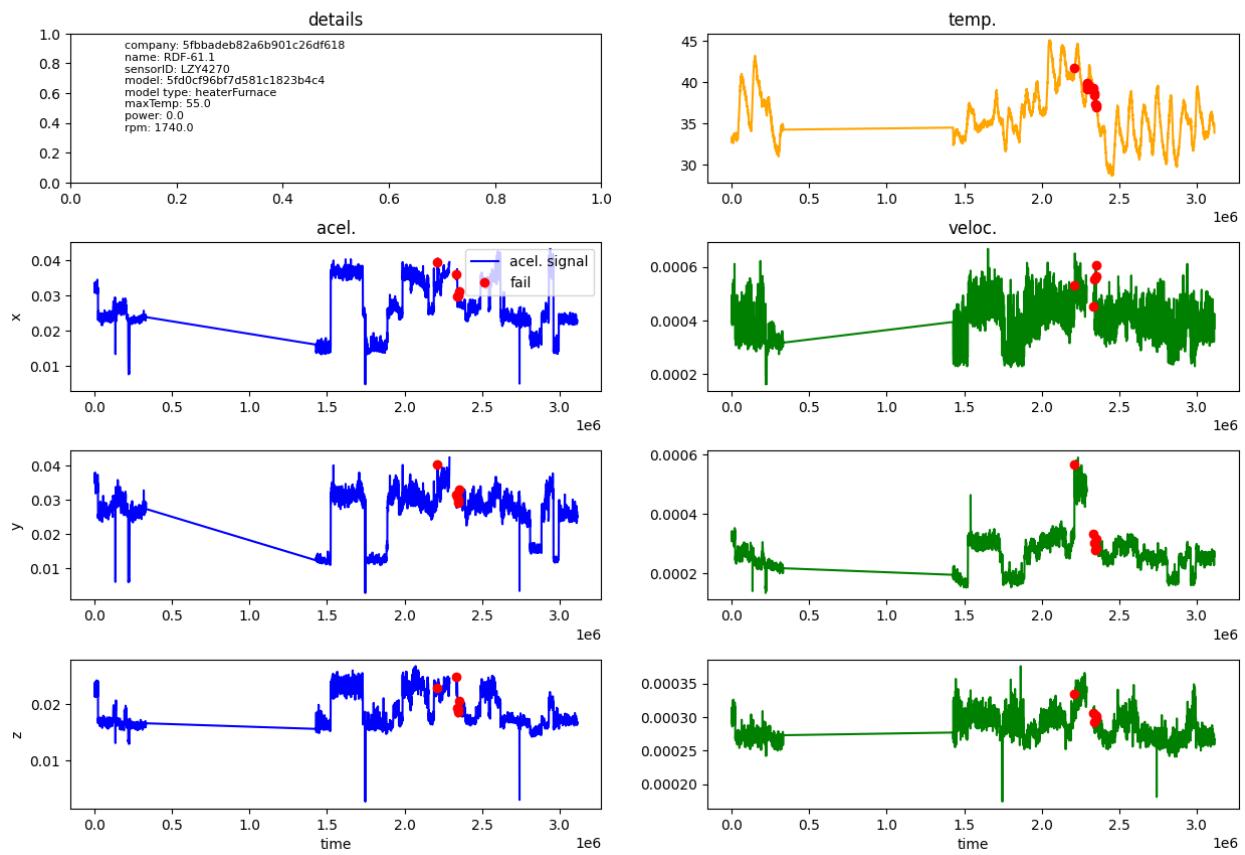


Figura 38. Detecção de falhas - Asset01

Asset - TRANSFORMADOR 500 KVA N°1

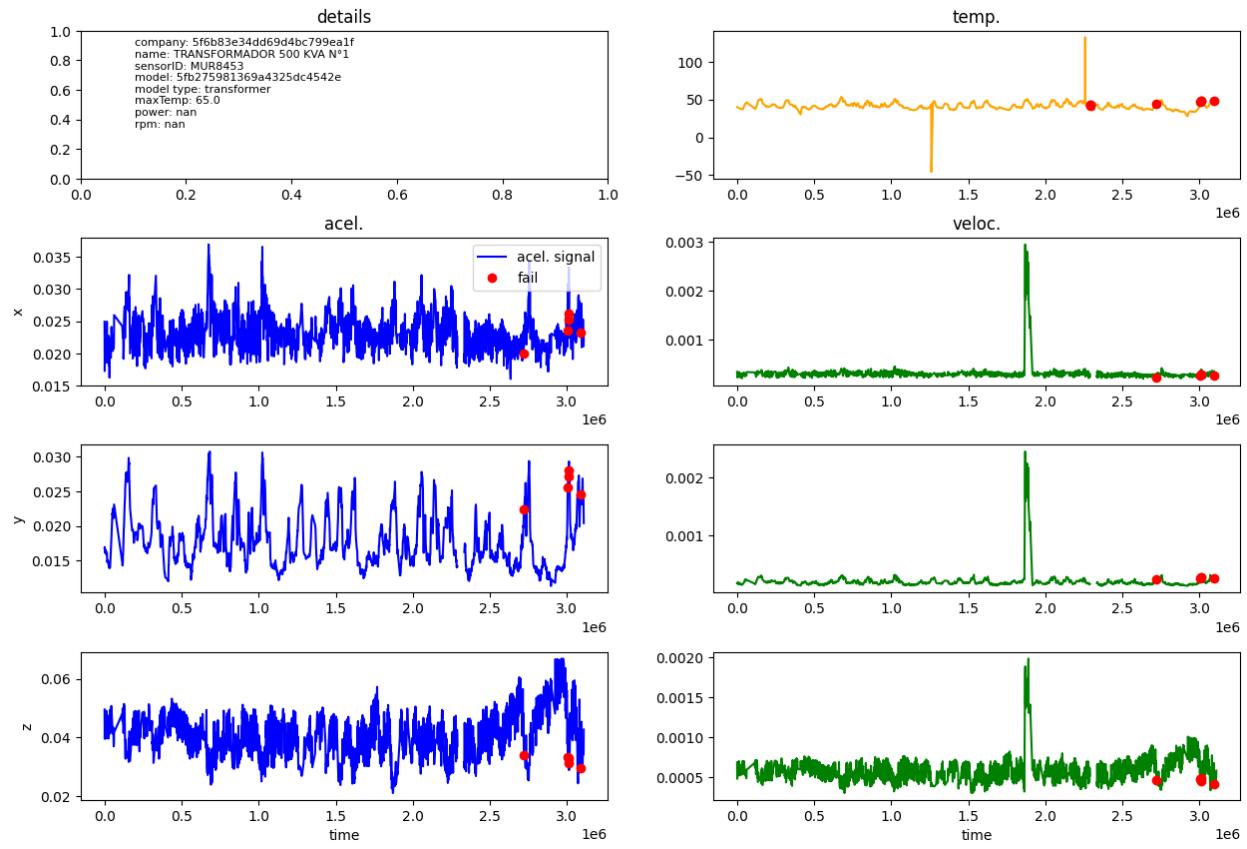


Figura 39. Detecção de falhas - Asset02

Asset - Motor Bomba - Tanque de Expansão Tubo Verde

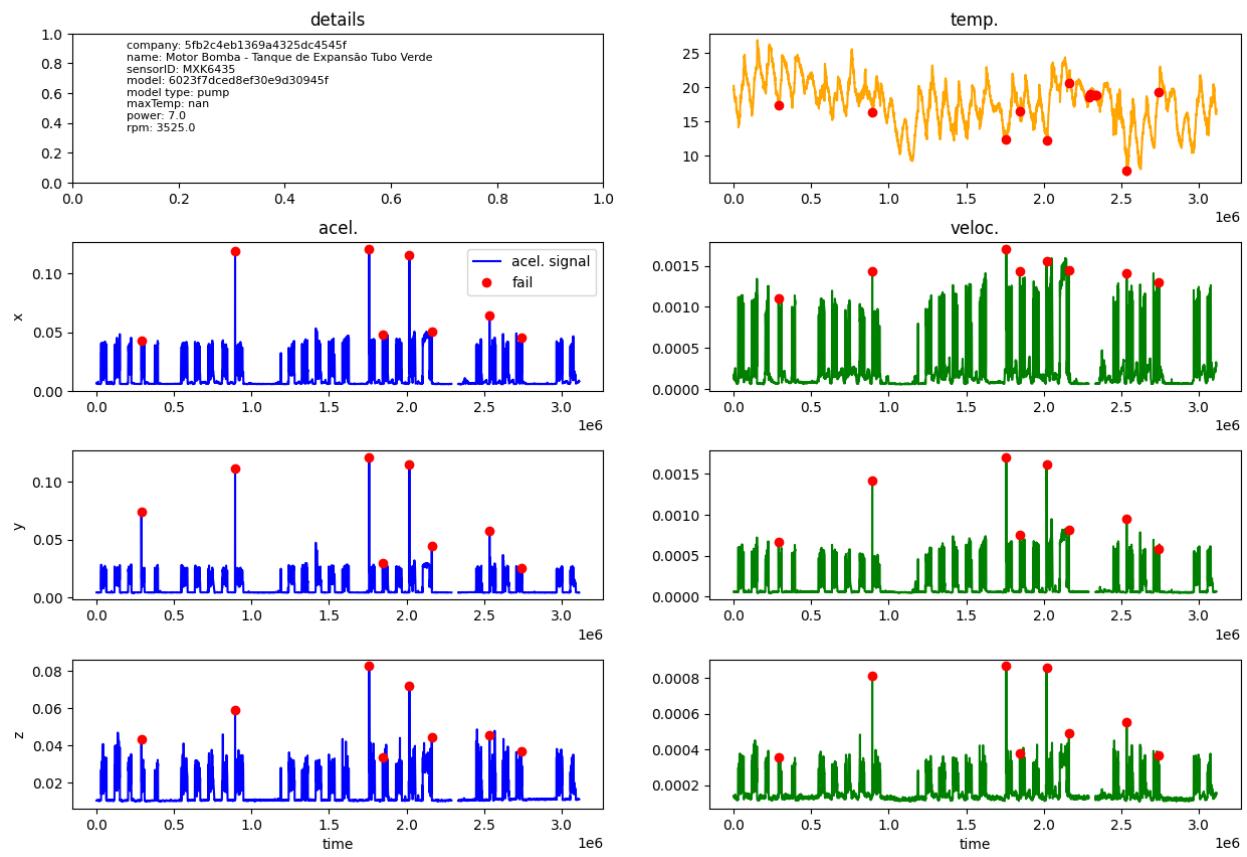


Figura 40. Detecção de falhas - Asset03

Asset - CAG1- BAGS.12- Motor

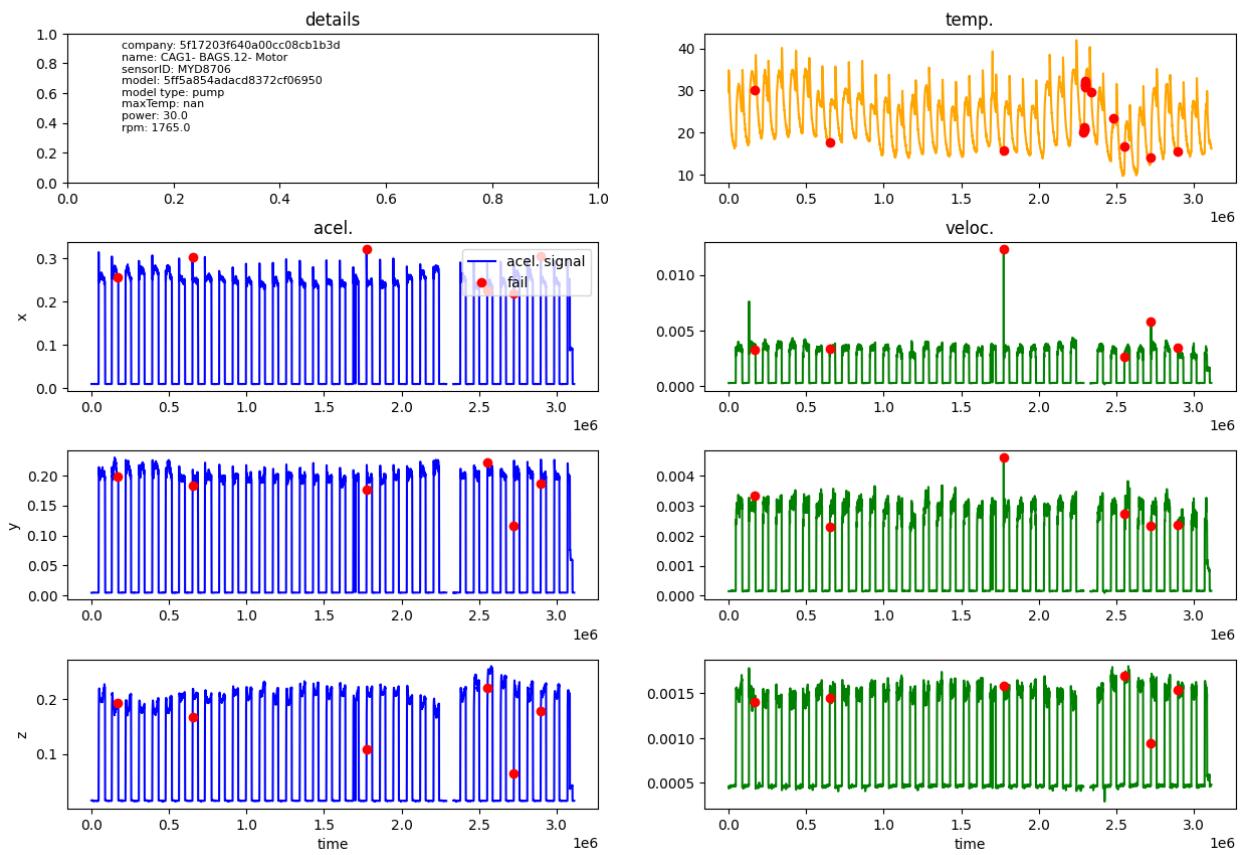


Figura 41. Detecção de falhas - Asset04

Asset - VTF-61.1

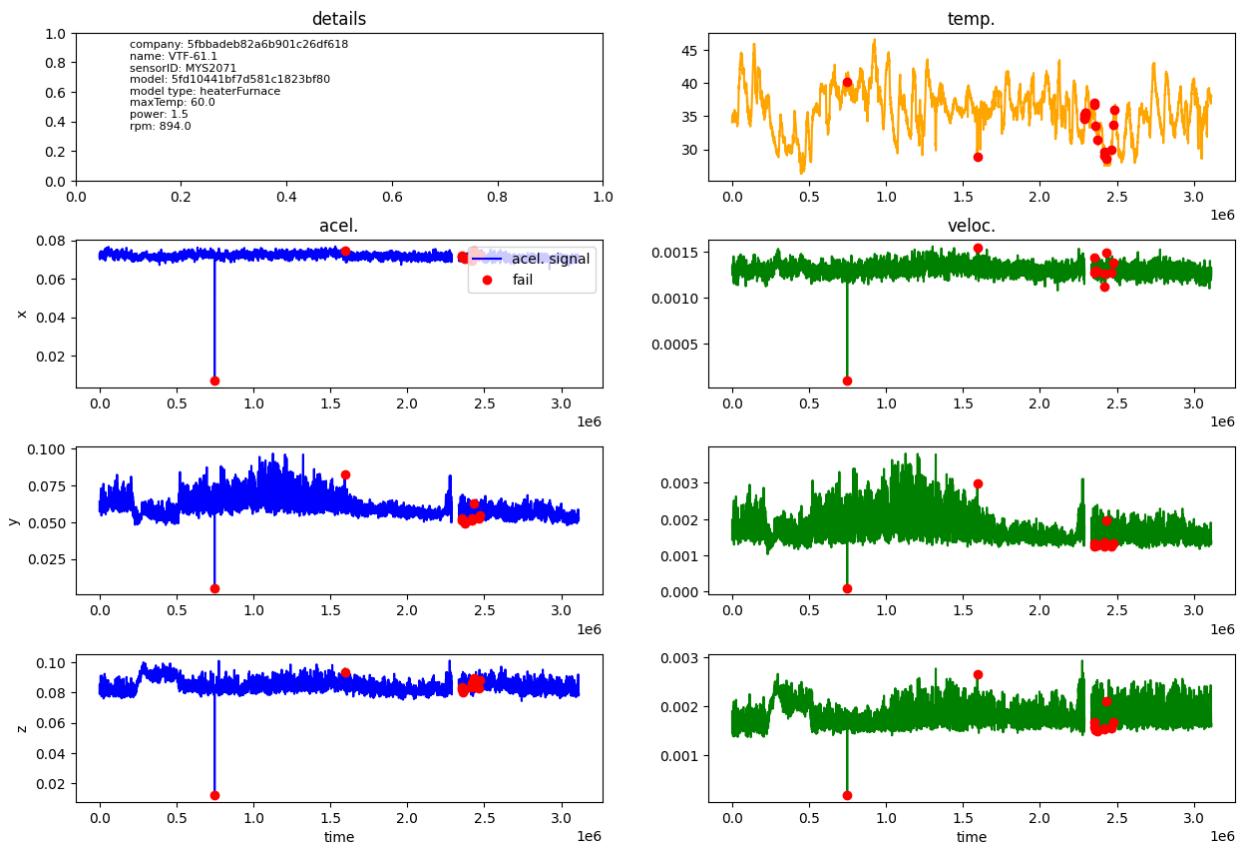


Figura 42. Detecção de falhas - Asset05

Asset - Boko MA-1510 - Motor 2 da UH

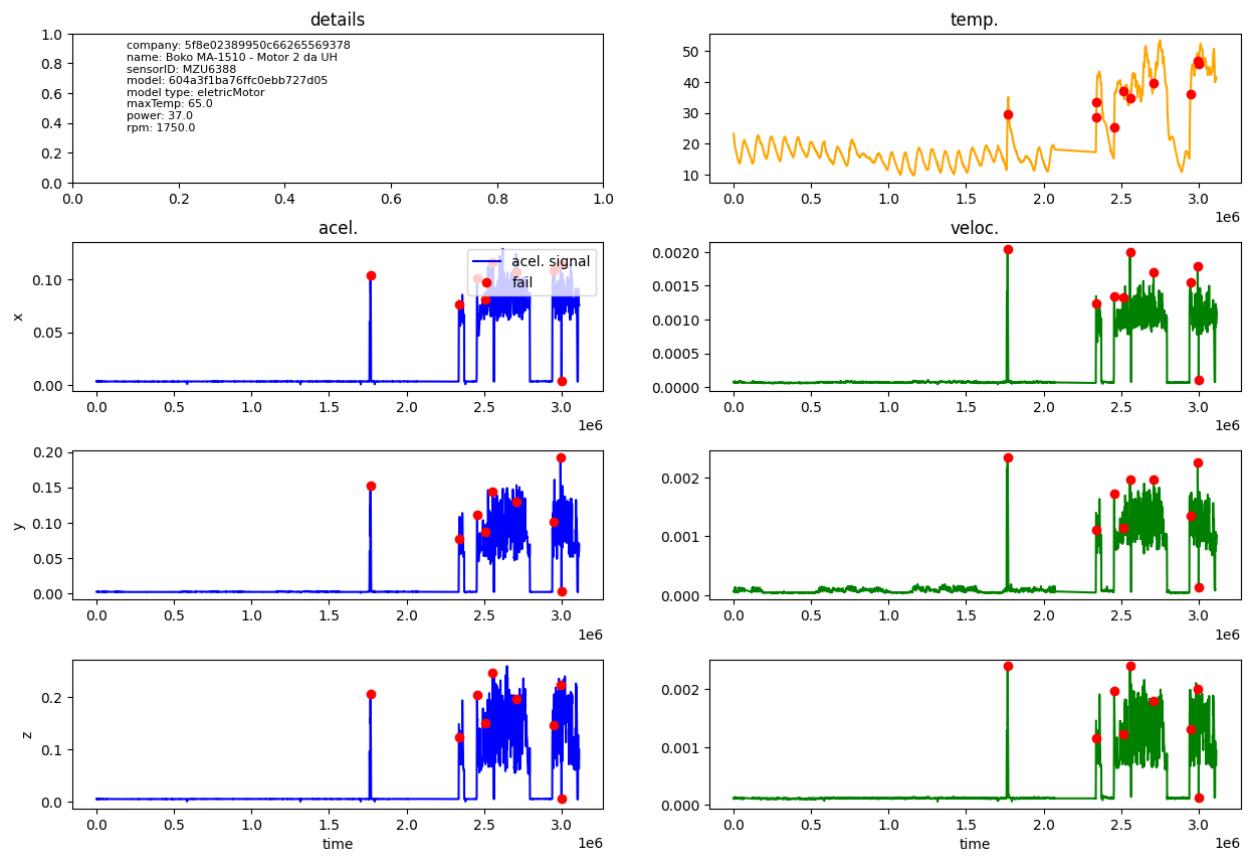


Figura 43. Detecção de falhas - Asset06

Asset - Ventilador -GA75 FF - Prédio B104

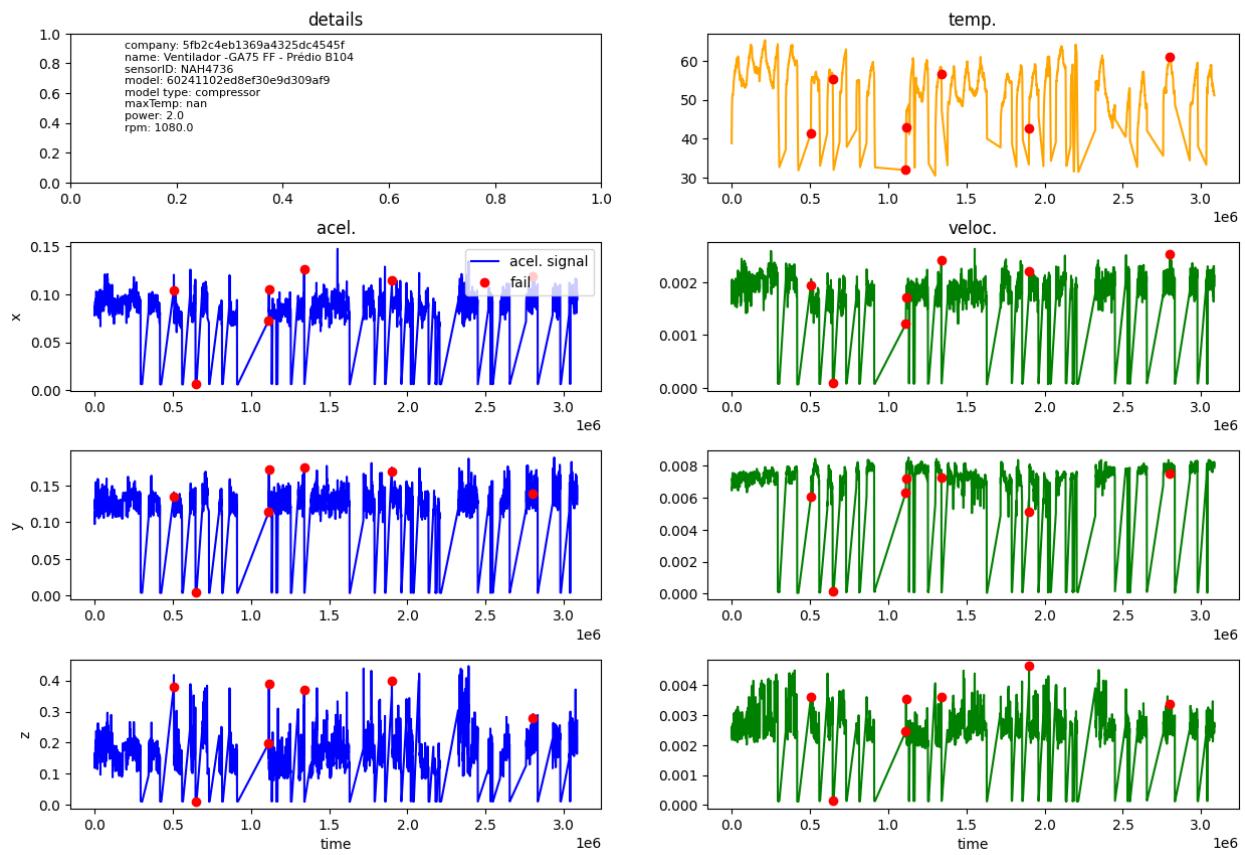


Figura 44. Detecção de falhas - Asset07

Asset - CAG1- BAGS.3- Motor

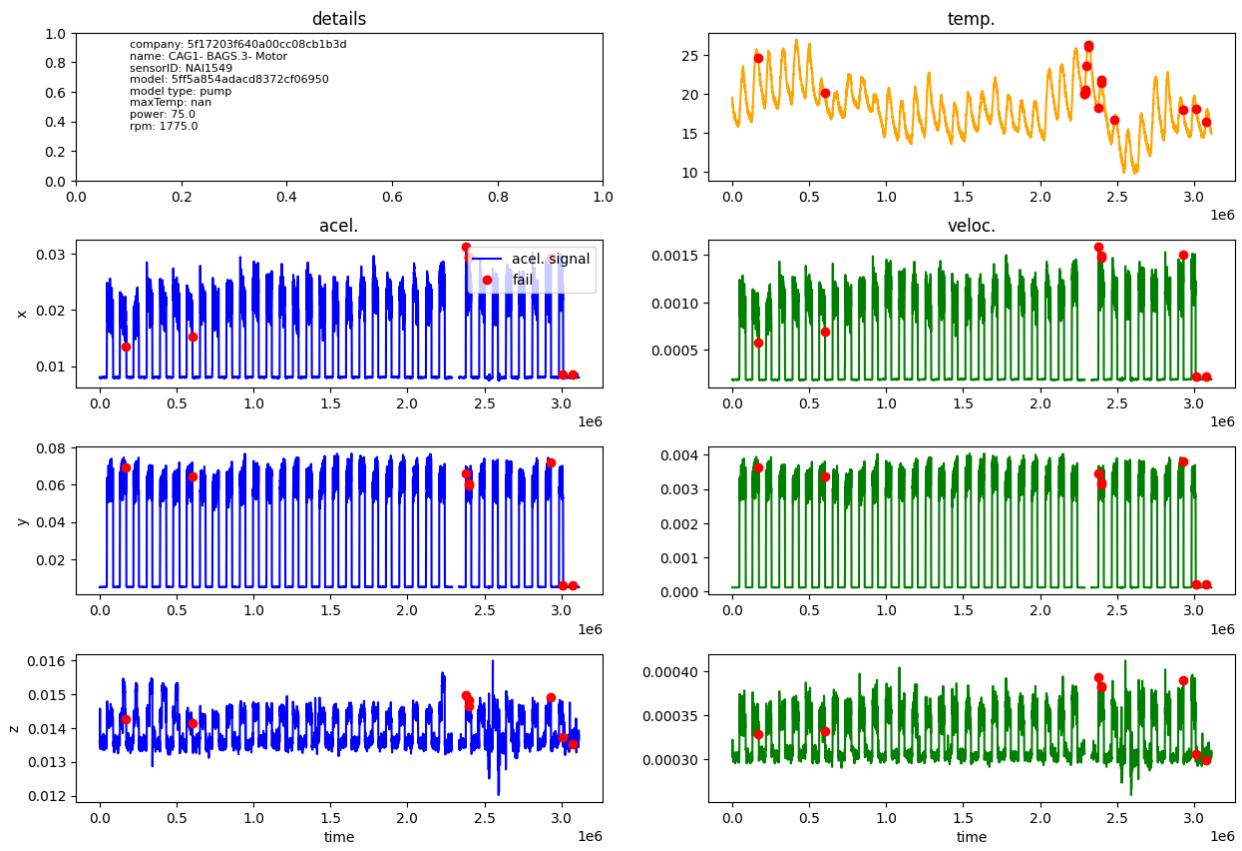


Figura 45. Detecção de falhas - Asset08

Asset - ROTULADORA SIDEL

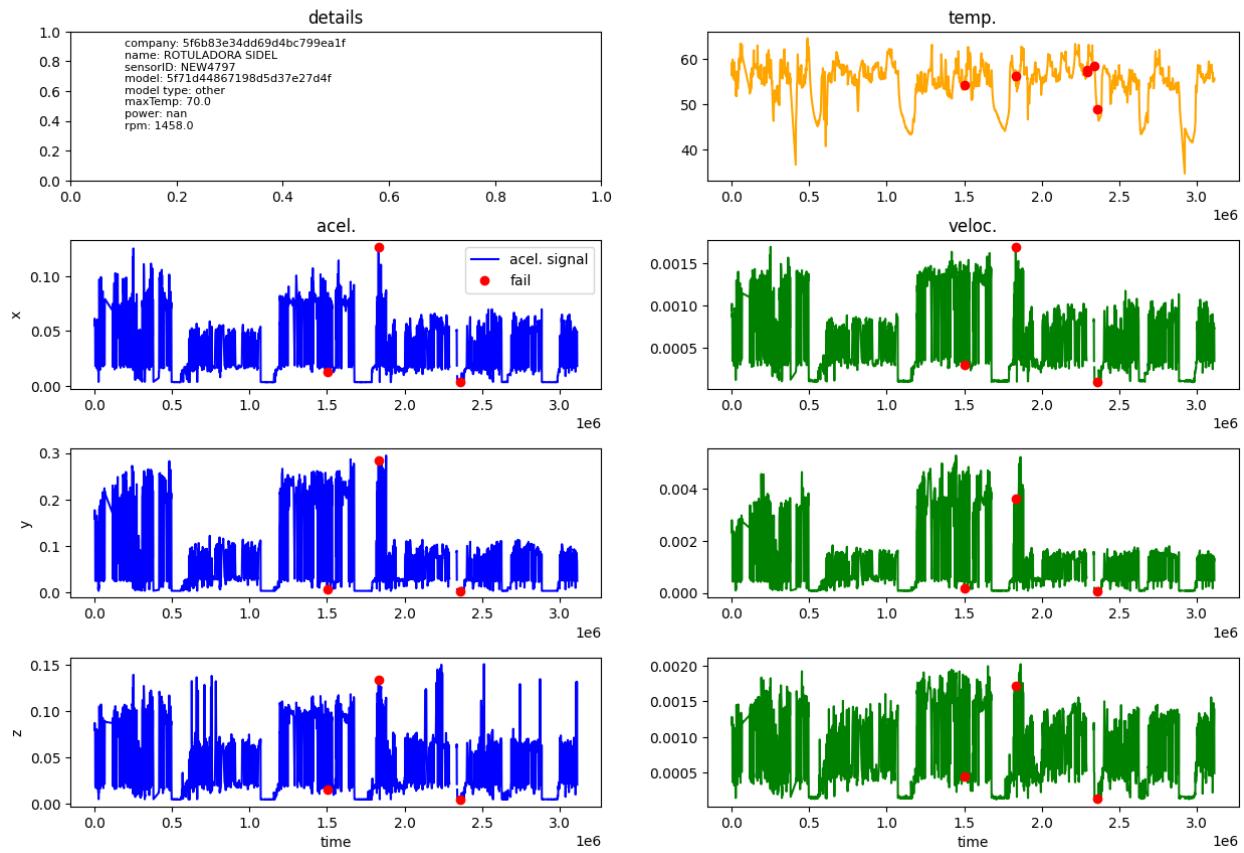


Figura 46. Detecção de falhas - Asset09

Conclusão

De forma geral o método proposto foi capaz de detectar outliers mais relevantes cruzando as informações capturadas pelos sensores. Visualmente é possível notar alguns falsos positivos e negativos. Uma possibilidade para aprimorar o resultado seria trazer buscar melhores configurações para a rede neural, como maior tempo de treinamento, configurar janelas e filtros de convolução de acordo com períodos identificados no sinal. Ou ainda, trabalhar com dados categorizados de forma que a rede neural fosse projetada para identificar diretamente casos de falha.